



(α) ΔΠΜΣ ΣΤΙΣ ΕΦΑΡΜΟΣΜΕΝΕΣ ΜΑΘΗΜΑΤΙΚΕΣ ΕΠΙΣΤΗΜΕΣ
(β) ΔΠΜΣ ΣΤΗΝ ΜΑΘΗΜΑΤΙΚΗ ΠΡΟΤΥΠΟΠΟΙΗΣΗ ΣΕ ΣΥΓΧΡΟΝΕΣ
ΤΕΧΝΟΛΟΓΙΕΣ ΚΑΙ ΣΤΗΝ ΟΙΚΟΝΟΜΙΑ

ΜΑΘΗΜΑ: *Μπεϋζιανή Στατιστική και MCMC*

ΔΙΔΑΣΚΩΝ: *ΔΗΜΗΤΡΗΣ ΦΟΥΣΚΑΚΗΣ (τηλ: 210 7721702 – email:*

fouskakis@math.ntua.gr)

ΕΡΓΑΣΙΑ

Άσκηση 1

Θεωρείστε ένα πρόβλημα πολλαπλής γραμμικής παλινδρόμησης με $n = 50$ παρατηρήσεις και $p = 15$ επεξηγηματικές μεταβλητές. Χρησιμοποιώντας έτοιμες συναρτήσεις στην R, προσομοιώστε τιμές για τις δέκα πρώτες επεξηγηματικές μεταβλητές από την πολυδιάστατη Κανονική κατανομή με μέση τιμή **0** και πίνακα συνδιακύμανσης τον ταυτοτικό, ενώ για τις υπόλοιπες προσομοιώστε τιμές με βάση την σχέση:

$$X_{ij} \sim N(0.3X_{i1} + 0.5X_{i2} + 0.7X_{i3} + 0.9X_{i4} + 1.5X_{i5}, \sigma^2 = 1), \quad j = 11, \dots, 15 \text{ και } i = 1, \dots, 50.$$

Για την μεταβλητή απόκρισης, προσομοιώστε τιμές, με τη βοήθεια της R, με βάση τη σχέση

$$Y_i \sim N(4 + 2X_{i1} - X_{i5} + 1.5X_{i7} + X_{i11} + 0.5X_{i13}, \sigma^2 = 2.5^2), \quad i = 1, \dots, 50.$$

Εν συνεχεία θεωρείστε το πολλαπλό γραμμικό μοντέλο

$$Y = \beta_0 + \beta_1 X_1 + \dots + \beta_{15} X_{15} + \varepsilon \equiv X\beta + \varepsilon, \quad \varepsilon \sim N(0, \sigma^2)$$

όπου X είναι ο πίνακας σχεδιασμού διάστασης 50×16 και $\beta = (\beta_0, \beta_1, \dots, \beta_{15})^T$.

Θεωρείστε τις παρακάτω (συζυγείς) πρότερες κατανομές:

$$\beta | \sigma^2 \sim N_{16}(\mathbf{0}, \sigma^2 \mathbf{M}^{-1})$$

$$\sigma^2 \sim \text{IG}(0.0001, 0.0001).$$

όπου M είναι ένας 16×16 θετικά ορισμένος συμμετρικός πίνακας.

A) Αποδείξτε ότι η πιθανοφάνεια του παραπάνω μοντέλου έχει την μορφή¹

$$\ell(\boldsymbol{\beta}, \sigma^2 | (\mathbf{y}, \mathbf{X})) = (2\pi\sigma^2)^{-n/2} \exp\left[-\frac{1}{2\sigma^2} s^2 - \frac{1}{2\sigma^2} (\boldsymbol{\beta} - \hat{\boldsymbol{\beta}})^T (\mathbf{X}^T \mathbf{X}) (\boldsymbol{\beta} - \hat{\boldsymbol{\beta}})\right],$$

όπου $\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$, $s^2 = (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})^T (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})$ και $\mathbf{y}$ το διάνυσμα με τις τιμές της μεταβλητής απόκρισης. Παρατηρήστε οπότε πως η πιθανοφάνεια ως συνάρτηση των $\boldsymbol{\beta}$ και σ^2 είναι μια *Multivariate Normal – Inverse Gamma* κατανομή.

B) Χρησιμοποιώντας την παρακάτω ταυτότητα:

$$\begin{aligned} & \boldsymbol{\beta}^T (M + \mathbf{X}^T \mathbf{X}) \boldsymbol{\beta} - 2\hat{\boldsymbol{\beta}}^T (\mathbf{X}^T \mathbf{X}) \boldsymbol{\beta} = \\ & = \left(\boldsymbol{\beta} - (M + \mathbf{X}^T \mathbf{X})^{-1} (\mathbf{X}^T \mathbf{X}) \hat{\boldsymbol{\beta}} \right)^T (M + \mathbf{X}^T \mathbf{X}) \left(\boldsymbol{\beta} - (M + \mathbf{X}^T \mathbf{X})^{-1} (\mathbf{X}^T \mathbf{X}) \hat{\boldsymbol{\beta}} \right) \\ & - \hat{\boldsymbol{\beta}}^T (\mathbf{X}^T \mathbf{X}) (M + \mathbf{X}^T \mathbf{X})^{-1} (\mathbf{X}^T \mathbf{X}) \hat{\boldsymbol{\beta}} \end{aligned}$$

καθώς και την σχέση

$$(M + \mathbf{X}^T \mathbf{X})^{-1} = (\mathbf{X}^T \mathbf{X})^{-1} - (\mathbf{X}^T \mathbf{X})^{-1} \left(M^{-1} + (\mathbf{X}^T \mathbf{X})^{-1} \right)^{-1} (\mathbf{X}^T \mathbf{X})^{-1}$$

αποδείξτε² ότι η ύστερη δεσμευμένη κατανομή του $\boldsymbol{\beta} | (\sigma^2, \mathbf{y}, \mathbf{X})$ είναι πολυδιάστατη (διάστασης 16) Κανονική κατανομή

$$N_{16} \left((M + \mathbf{X}^T \mathbf{X})^{-1} (\mathbf{X}^T \mathbf{X}) \hat{\boldsymbol{\beta}}, \sigma^2 (M + \mathbf{X}^T \mathbf{X})^{-1} \right)$$

και η περιθώρια ύστερη κατανομή του $\sigma^2 | (\mathbf{y}, \mathbf{X})$ είναι η

$$IG \left(\frac{n}{2} + a, b + \frac{s^2}{2} + \frac{\hat{\boldsymbol{\beta}}^T (M^{-1} + (\mathbf{X}^T \mathbf{X})^{-1})^{-1} \hat{\boldsymbol{\beta}}}{2} \right).$$

Γ) Χρησιμοποιώντας το *WinBugs* προσομοιώστε τιμές από τις ύστερες κατανομές των β_j ($j = 0, \dots, 15$) και του σ^2 . Θεωρήστε ότι ο M είναι ένας διαγώνιος πίνακας όπου όλες οι τιμές στην διαγώνιο είναι ίσες με 10000. Συγκρίνεται τα αποτελέσματά σας με αυτά από την κλασική στατιστική. Συγκρίνετε με θηκογραφήματα τις ύστερες

¹ Δείξτε ότι $(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})^T \mathbf{X}(\boldsymbol{\beta} - \hat{\boldsymbol{\beta}}) = 0$.

² Παρατηρείστε ότι $\boldsymbol{\beta}^T (\mathbf{X}^T \mathbf{X}) \hat{\boldsymbol{\beta}} \in \mathbb{R}$ και $\hat{\boldsymbol{\beta}}^T (\mathbf{X}^T \mathbf{X}) \boldsymbol{\beta} \in \mathbb{R}$.

κατανομές των συντελεστών παλινδρόμησης. Ποιες επεξηγηματικές μεταβλητές θα αφαιρούσατε από το μοντέλο με βάση αυτά τα γραφήματα; Είναι οι πραγματικές τιμές των συντελεστών στο κέντρο των υστέρων κατανομών;

Δ) Γράψτε τον δικό σας αλγόριθμο *Gibbs* στην R, υπό μορφή συνάρτησης, ώστε να προσομοιώσετε τιμές από τις ύστερες κατανομές των β_j ($j = 0, \dots, 15$) και του σ^2 . Θεωρήστε ότι ο M είναι ένας διαγώνιος πίνακας όπου όλες οι τιμές στην διαγώνιο είναι ίσες με 10000. Συγκρίνεται τα αποτελέσματά σας με αυτά από την κλασική στατιστική και αυτά του B) ερωτήματος.

Άσκηση 2

Έστω ότι ο αριθμός των καθημερινών σφαλμάτων σε ένα διακομιστή ακολουθεί την κατανομή Poisson με άγνωστη παράμετρο $\lambda > 0$. Έστω ότι σε διάστημα 10 ημερών παρατηρήσαμε συνολικά 35 σφάλματα.

A) Έστω ότι θέλετε να κάνετε τον Μπεϋζιανό έλεγχο υπόθεσης:

$$H_0: \lambda = 2 \text{ έναντι της } H_1: \lambda \neq 2.$$

Υπολογίστε αναλυτικά τις περιθώριες πιθανοφάνειες κάτω από τη μηδενική και εναλλακτική υπόθεση. Δουλέψτε με τις κατανομές του επαρκούς στατιστικού. Κάτω από την εναλλακτική υπόθεση θεωρήστε a-priori πως το $\lambda \sim \text{Gamma}(\text{shape}=2, \text{rate}=1)$. Εξηγήστε γιατί αυτή η πρότερη κατανομή αντιπροσωπεύει μια ασθενή πεποίθηση ότι ο ρυθμός κυμαίνεται γύρω από το 2 (μηδενική υπόθεση). Θεωρήστε επιπλέον a-priori πως οι δύο υποθέσεις είναι εξίσου πιθανές. Υπολογίστε αναλυτικά τον παράγοντα Μπέϋζ της εναλλακτικής υπόθεσης έναντι της μηδενικής και συνδέστε τον με τον ύστερο λόγο των συμπληρωματικών πιθανοτήτων (*posterior odds* – PO_{10}). Ποιο είναι το τελικό σας συμπέρασμα;

B) Κάτω από την εναλλακτική υπόθεση, υπολογίστε αναλυτικά την ύστερη προβλεπτική κατανομή της 11^{ης} παρατήρησης. Βρείτε την αναμενόμενη τιμή και διασπορά της εν λόγω κατανομής και συγκρίνετέ την με τα αντίστοιχα μέτρα από την προβλεπτική κατανομή κάτω από την κλασική στατιστική. Σχολιάστε. Ποια είναι η ύστερη πιθανότητα η 11^η παρατήρηση να έχει τιμή άνω του 5;

Άσκηση 3

Από όποια πηγή επιθυμείτε βρείτε κάποια δεδομένα αντίστοιχα με αυτά του Παραδείγματος 3 με τα ποντίκια που κάναμε στην τάξη στο τελευταίο σετ διαφανειών. Θεωρήστε δηλαδή ότι η μεταβλητή απόκρισης ακολουθεί την δυωνυμική κατανομή και η επεξηγηματική σας μεταβλητή είναι κατηγορική με 3 ή περισσότερες κατηγορίες. Για μία μόνο από τις κατηγορίες της επεξηγηματικής σας μεταβλητής υποθέστε ότι το ίδιο πείραμα είχε επαναληφθεί στο παρελθόν, υποθέστε κάποια δεδομένα για αυτό και εισάγετε κατάλληλα την πληροφορία αυτή στην πρότερη κατανομή της τωρινής σας ανάλυσης. Με την βοήθεια του *WinBugs*, βγάλτε κατάλληλα συμπεράσματα και συγκρίνετε τα αποτελέσματα σας με αυτά από την κλασική στατιστική.

Άσκηση 4

Για το πρόβλημα της Άσκησης 2, κάτω από την εναλλακτική υπόθεση, βρείτε αναλυτικά την Jeffreys prior για το λ . Με χρήση της εν λόγω πρότερης και δικού σας κώδικα στην R, προσομοιώστε 20000 τιμές από την ύστερη κατανομή του λ χρησιμοποιώντας τον αλγόριθμο *Metropolis-Hastings*. Ως κατανομή εισήγησης χρησιμοποιήστε την κανονική κατανομή με μέση τιμή την τρέχουσα τιμή της αλυσίδας σας και κατάλληλα επιλεγμένη διασπορά ώστε να επιλέγονται περίπου το 25% των προτεινόμενων τιμών σας. Δώστε ιστογράμματα και περιγραφικούς πίνακες των προσομοιωμένων τιμών. Δώστε επίσης *trace plots*, *ergodic mean plots* και διαγράμματα αυτοσυσχετίσεων και συζητήστε για την σύγκλιση του αλγορίθμου σας καθώς και για την επιλογή του *burn-in* και του συνολικού αριθμού επαναλήψεων. Τέλος με τη βοήθεια των προσομοιωμένων σας τιμών εκτιμήστε το συμμετρικό 95% διάστημα αξιοπιστίας και ερμηνεύστε το.

Οδηγίες

- Η εργασία θα πρέπει να παραδοθεί ηλεκτρονικά στο email μου, fouskakis@math.ntua.gr, μέχρι τη Δευτέρα 15 Ιουνίου 2026 στις 13:00μμ. Καμιά εργασία δεν θα γίνει δεκτή μετά την ώρα αυτή.
- Η εργασία που θα παραδώσετε πρέπει να είναι σε pdf μορφή αφού πρώτα την γράψετε υποχρεωτικά σε Latex. Παρακαλώ χρησιμοποιήστε τον ακόλουθο τίτλο στο pdf αρχείο σας: Surname-Name.pdf, όπου Surname

είναι το επώνυμό σας (με λατινικούς χαρακτήρες) και Name το όνομα σας (με λατινικούς χαρακτήρες). Π.χ. αν παρέδιδα εγώ την εργασία θα την ονόμαζα ως εξής: Fouskakakis-Dimitris.pdf.

- Παρακαλώ χρησιμοποιήστε **ένα εξώφυλλο στο pdf αρχείο σας**, στο οποίο να υπάρχει κατάλληλος τίτλος και να αναγράφεται **υποχρεωτικά το ονοματεπώνυμο σας, το μεταπτυχιακό πρόγραμμα που παρακολουθείτε καθώς και το email σας και ο αριθμός μητρώου σας**.
- Θα πρέπει να **αποστέιλετε ένα μόνο αρχείο**. Η εργασία θα πρέπει να περιλαμβάνει τους κώδικες της R και του Winbugs, όχι σε παράρτημα αλλά στην απάντηση του κάθε ερωτήματος, με πλήρη επεξήγηση. Επιπλέον θα πρέπει να υπάρχουν γραφήματα, πίνακες και πλήρη περιγραφή των αποτελεσμάτων.
- Θα δοθεί ιδιαίτερη σημασία στην παρουσίαση της εργασίας. Η εργασία πρέπει να είναι κατανοητή και να περιγράφει οτιδήποτε χρησιμοποιήσατε πειστικά για κάποιον που δεν γνωρίζει πάρα πολλά για το αντικείμενο.
- Την **Τρίτη 23 Ιουνίου 2026** θα υπάρξει παρουσίαση της εργασίας στο PC Lab του Τομέα Μαθηματικών. **Η παρουσιάσεις θα ξεκινήσουν στις 10.00πμ**. Όλοι οι φοιτητές εκείνη την μέρα θα πρέπει να παρευρίσκονται σε όλες τις παρουσιάσεις και ο κάθε ένας μεμονωμένα θα παρουσιάζει μέρος της εργασίας του. **Η παρουσία όλων εκείνη την μέρα είναι υποχρεωτική. Σε περίπτωση απουσίας η εργασία δεν θα βαθμολογηθεί.** Για την παρουσίαση θα πρέπει να έχετε μαζί σας σε ένα usb stick την εργασία σας σε μορφή pdf.
- Μετά το πέρας των παρουσιάσεων θα καλέσω τον κάθε φοιτητή μεμονωμένα στο γραφείο μου, για τα τελικά σχόλια και την ανακοίνωση του βαθμού του.

Εύχομαι Επιτυχία