



ΕΘΝΙΚΟ ΜΕΤΣΟΒΙΟ ΠΟΛΥΤΕΧΝΕΙΟ
ΣΧΟΛΗ ΕΦΑΡΜΟΣΜΕΝΩΝ ΜΑΘΗΜΑΤΙΚΩΝ ΚΑΙ ΦΥΣΙΚΩΝ
ΕΠΙΣΤΗΜΩΝ
ΔΠΜΣ ΣΤΗΝ ΜΑΘΗΜΑΤΙΚΗ ΠΡΟΤΥΠΟΠΟΙΗΣΗ ΣΕ ΣΥΓΧΡΟΝΕΣ
ΤΕΧΝΟΛΟΓΙΕΣ ΚΑΙ ΣΤΗΝ ΧΡΗΜΑΤΟΟΙΚΟΝΟΜΙΚΗ

Μπεϋζιανή Στατιστική και MCMC

Εργασία Εαρινού Εξαμήνου 2026

Λιδάσκων:
Δημήτρης Φουσκάκης

Παυλίνα Κόγια
ΑΜ: 09325011

Ιούνιος 2026

Άσκηση 1

Ερώτημα Α

Στόχος του ερωτήματος είναι να γραφεί η συνάρτηση πιθανοφάνειας $\ell(\beta, \sigma^2 \mid \mathbf{y}, X)$ σε κλειστή μορφή που αναγνωρίζεται ως πυρήνας γνωστής κατανομής. Αυτό είναι κρίσιμο βήμα για την Bayesian ανάλυση: μας επιτρέπει να υπολογίσουμε αναλυτικά την ύστερη κατανομή των παραμέτρων, αξιοποιώντας τις συζυγείς πρότερες κατανομές που θα εισαχθούν στο Ερώτημα Β.

Το Μοντέλο

Θεωρούμε το πολλαπλό γραμμικό μοντέλο:

$$\mathbf{Y} = \mathbf{X}\beta + \varepsilon, \quad \varepsilon \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_n)$$

όπου $\mathbf{X}$ είναι ο πίνακας σχεδιασμού διάστασης 50×16 και $\beta = (\beta_0, \beta_1, \dots, \beta_{15})^\top$.

Επειδή $\varepsilon \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_n)$, κάθε Y_i είναι ανεξάρτητη και:

$$Y_i \mid \beta, \sigma^2 \sim N(\mathbf{x}_i^\top \beta, \sigma^2)$$

με συνάρτηση πυκνότητας:

$$f(y_i \mid \beta, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{(y_i - \mathbf{x}_i^\top \beta)^2}{2\sigma^2}\right\}$$

Κατασκευή της Πιθανοφάνειας

Η συνάρτηση πιθανοφάνειας είναι το γινόμενο των επιμέρους πυκνοτήτων (λόγω ανεξαρτησίας):

$$\begin{aligned} \ell(\beta, \sigma^2 \mid \mathbf{y}, \mathbf{X}) &= \prod_{i=1}^n f(y_i \mid \beta, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{(y_i - \mathbf{x}_i^\top \beta)^2}{2\sigma^2}\right\} \\ &= (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mathbf{x}_i^\top \beta)^2\right\} \end{aligned}$$

Επειδή $\sum_{i=1}^n (y_i - \mathbf{x}_i^\top \beta)^2 = \|\mathbf{y} - \mathbf{X}\beta\|^2 = (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta)$, έχουμε:

$$\ell(\beta, \sigma^2 \mid \mathbf{y}, \mathbf{X}) = (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2} (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta)\right\}$$

Ορισμός και Εύρεση του OLS/MLE Εκτιμητή

Ο εκτιμητής μέγιστης πιθανοφάνειας (MLE) ισοδυναμεί με τον εκτιμητή ελαχίστων τετραγώνων (OLS): Η μεγιστοποίηση της πιθανοφάνειας ως προς β :

$$\max_{\beta} \ell(\beta, \sigma^2 \mid \mathbf{y}, \mathbf{X}) = \max_{\beta} (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbf{X}\beta\|^2\right)$$

Επειδή ο παράγοντας $(2\pi\sigma^2)^{-n/2}$ δεν εξαρτάται από το β και το $\exp$ είναι αύξουσα συνάρτηση, η μεγιστοποίηση ισοδυναμεί με:

$$\max_{\beta} \exp\left(-\frac{1}{2\sigma^2}\|\mathbf{y} - \mathbf{X}\beta\|^2\right) = \min_{\beta} \|\mathbf{y} - \mathbf{X}\beta\|^2$$

το οποίο είναι ακριβώς το κριτήριο των ελαχίστων τετραγώνων (OLS).

$$\hat{\beta} = \arg \max_{\beta} \ell(\beta, \sigma^2 | \mathbf{y}, \mathbf{X}) = \arg \min_{\beta} \|\mathbf{y} - \mathbf{X}\beta\|^2$$

Ορίζουμε την αντικειμενική συνάρτηση:

$$Q(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|^2 = \mathbf{y}^\top \mathbf{y} - 2\beta^\top \mathbf{X}^\top \mathbf{y} + \beta^\top \mathbf{X}^\top \mathbf{X} \beta$$

χρησιμοποιώντας ότι $\mathbf{y}^\top \mathbf{X} \beta = \beta^\top \mathbf{X}^\top \mathbf{y}$, καθώς είναι βαθμωτό.

Παραγωγίζουμε ως προς β και μηδενίζουμε:

$$\frac{\partial Q}{\partial \beta} = -2\mathbf{X}^\top \mathbf{y} + 2\mathbf{X}^\top \mathbf{X} \beta = \mathbf{0} \implies \mathbf{X}^\top \mathbf{X} \hat{\beta} = \mathbf{X}^\top \mathbf{y} \quad (\text{Κανονικές Εξισώσεις})$$

Ο $\mathbf{X}^\top \mathbf{X}$ είναι αντιστρέψιμος (οι στήλες του $\mathbf{X}$ είναι γραμμικώς ανεξάρτητες), άρα:

$$\boxed{\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}}$$

Επιπλέον, $\nabla^2 Q = 2\mathbf{X}^\top \mathbf{X}$ είναι θετικά ημιορισμένος αφού $\mathbf{v}^\top (\mathbf{X}^\top \mathbf{X}) \mathbf{v} = \|\mathbf{X}\mathbf{v}\|^2 \geq 0$, άρα η Q είναι κυρτή και το $\hat{\beta}$ είναι ελάχιστο.

Ορισμός του s^2

$$s^2 = (\mathbf{y} - \mathbf{X}\hat{\beta})^\top (\mathbf{y} - \mathbf{X}\hat{\beta}) = \|\mathbf{y} - \mathbf{X}\hat{\beta}\|^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Λήμμα 1. Ισχύει ότι $(\mathbf{y} - \mathbf{X}\hat{\beta})^\top \mathbf{X}(\beta - \hat{\beta}) = 0$.

Απόδειξη. Από τις Κανονικές Εξισώσεις έχουμε $\mathbf{X}^\top \mathbf{X} \hat{\beta} = \mathbf{X}^\top \mathbf{y}$, άρα $\mathbf{X}^\top (\mathbf{y} - \mathbf{X}\hat{\beta}) = \mathbf{0}$. Επομένως:

$$(\mathbf{y} - \mathbf{X}\hat{\beta})^\top \mathbf{X}(\beta - \hat{\beta}) = \left[\mathbf{X}^\top (\mathbf{y} - \mathbf{X}\hat{\beta}) \right]^\top (\beta - \hat{\beta}) = \mathbf{0}^\top (\beta - \hat{\beta}) = 0.$$

□

Απόδειξη Τελικής Μορφής

Προσθέτουμε και αφαιρούμε το $\mathbf{X}\hat{\beta}$:

$$\mathbf{y} - \mathbf{X}\beta = \underbrace{(\mathbf{y} - \mathbf{X}\hat{\beta})}_{\mathbf{a}} - \underbrace{\mathbf{X}(\beta - \hat{\beta})}_{\mathbf{b}}$$

Άρα $\|\mathbf{a} - \mathbf{b}\|^2 = \mathbf{a}^\top \mathbf{a} - 2\mathbf{a}^\top \mathbf{b} + \mathbf{b}^\top \mathbf{b}$:

$$\|\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}\|^2 = \underbrace{(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})^\top (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})}_{=s^2} - 2 \underbrace{(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})^\top \mathbf{X}(\boldsymbol{\beta} - \hat{\boldsymbol{\beta}})}_{=0} + (\boldsymbol{\beta} - \hat{\boldsymbol{\beta}})^\top \mathbf{X}^\top \mathbf{X}(\boldsymbol{\beta} - \hat{\boldsymbol{\beta}})$$

Ο διασταυρούμενος όρος μηδενίζεται λόγω των Κανονικών Εξισώσεων:

$$(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})^\top \mathbf{X}(\boldsymbol{\beta} - \hat{\boldsymbol{\beta}}) = \underbrace{\left[\mathbf{X}^\top (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) \right]^\top}_{=\mathbf{0}^\top} (\boldsymbol{\beta} - \hat{\boldsymbol{\beta}}) = 0$$

διότι $\mathbf{X}^\top \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{y} \iff \mathbf{X}^\top (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) = \mathbf{0}$.

Άρα:

$$\|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2 = s^2 + (\boldsymbol{\beta} - \hat{\boldsymbol{\beta}})^\top (\mathbf{X}^\top \mathbf{X})(\boldsymbol{\beta} - \hat{\boldsymbol{\beta}})$$

Αντικαθιστώντας στην πιθανοφάνεια:

$$\ell(\boldsymbol{\beta}, \sigma^2 \mid \mathbf{y}, \mathbf{X}) = (2\pi\sigma^2)^{-n/2} \exp\left\{ -\frac{1}{2\sigma^2}s^2 - \frac{1}{2\sigma^2}(\boldsymbol{\beta} - \hat{\boldsymbol{\beta}})^\top (\mathbf{X}^\top \mathbf{X})(\boldsymbol{\beta} - \hat{\boldsymbol{\beta}}) \right\}$$

Παρατήρηση: Multivariate Normal - Inverse Gamma Η πιθανοφάνεια ως συνάρτηση των $\boldsymbol{\beta}$ και σ^2 είναι πυρήνας *Multivariate Normal - Inverse Gamma* κατανομής:

- **Ως προς $\boldsymbol{\beta}$ (σταθερό σ^2):** Ο εκθέτης είναι τετραγωνική μορφή στο $\boldsymbol{\beta}$:

$$\ell \propto \exp\left\{ -\frac{1}{2\sigma^2}(\boldsymbol{\beta} - \hat{\boldsymbol{\beta}})^\top (\mathbf{X}^\top \mathbf{X})(\boldsymbol{\beta} - \hat{\boldsymbol{\beta}}) \right\}$$

που είναι πυρήνας $N_{16}\left(\hat{\boldsymbol{\beta}}, \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1}\right)$.

- **Ως προς σ^2 (σταθερό $\boldsymbol{\beta}$):** Η πιθανοφάνεια έχει τη μορφή $(\sigma^2)^{-n/2} \exp\left(-\frac{c}{\sigma^2}\right)$ με $c = \frac{s^2 + (\boldsymbol{\beta} - \hat{\boldsymbol{\beta}})^\top (\mathbf{X}^\top \mathbf{X})(\boldsymbol{\beta} - \hat{\boldsymbol{\beta}})}{2} > 0$. Αυτό είναι πυρήνας $IG\left(\frac{n}{2} - 1, c\right)$, αφού για $X \sim IG(\alpha, b)$ ισχύει $p(x) \propto x^{-\alpha-1}e^{-b/x}$, και εδώ ο εκθέτης του σ^2 είναι $-n/2$, που αντιστοιχεί σε $\alpha = n/2 - 1$.

Η διπλή αυτή αναγνώριση είναι η βάση για την επιλογή των συζυγών πρότερων κατανομών στο Ερώτημα Β: η συζυγής prior για $\boldsymbol{\beta} \mid \sigma^2$ είναι Κανονική και για σ^2 είναι Inverse Gamma, εξασφαλίζοντας αναλυτικές εκφράσεις για τις ύστερες κατανομές.

Ερώτημα Β

Στόχος είναι ο υπολογισμός δύο κατανομών από την από κοινού ύστερη $p(\boldsymbol{\beta}, \sigma^2 \mid \mathbf{y}, X)$:

1. Η **δεσμευμένη ύστερη** $\boldsymbol{\beta} \mid \sigma^2, \mathbf{y}, X$: χρησιμοποιείται στον Gibbs sampler (Ερώτημα Δ).
2. Η **περιθώρια ύστερη** $\sigma^2 \mid \mathbf{y}, X$: προκύπτει ολοκληρώνοντας ως προς $\boldsymbol{\beta}$.

Και οι δύο έχουν αναλυτική μορφή χάρη στις συζυγείς πρότερες κατανομές που επιλέχθηκαν στο Ερώτημα Α.

Πρότερες Κατανομές (Priors)

Από την εκφώνηση, οι συζυγείς πρότερες κατανομές είναι:

$$\boldsymbol{\beta} \mid \sigma^2 \sim N_{16}(\mathbf{0}, \sigma^2 \mathbf{M}^{-1}) \quad \text{και} \quad \sigma^2 \sim IG(a, b), \quad a = b = 0.0001$$

Ο πυρήνας της πρότερης κατανομής για $\boldsymbol{\beta} \mid \sigma^2$ προκύπτει από τον ορισμό της $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ με $\boldsymbol{\mu} = \mathbf{0}$ και $\boldsymbol{\Sigma} = \sigma^2 \mathbf{M}^{-1}$.
Έχουμε $\boldsymbol{\Sigma}^{-1} = (\sigma^2 \mathbf{M}^{-1})^{-1} = \frac{\mathbf{M}}{\sigma^2}$, άρα:

$$p(\boldsymbol{\beta} \mid \sigma^2) \propto (\sigma^2)^{-8} \exp\left\{-\frac{1}{2\sigma^2} \boldsymbol{\beta}^\top \mathbf{M} \boldsymbol{\beta}\right\}$$

Το $\mathbf{M}$ (και όχι $\mathbf{M}^{-1}$) εμφανίζεται γιατί είναι ο αντίστροφος του πίνακα συνδιακύμανσης $\boldsymbol{\Sigma}$.

Ο πυρήνας της πρότερης κατανομής για σ^2 προκύπτει από τον ορισμό της $IG(\alpha, b)$ με πυρήνα $(\sigma^2)^{-\alpha-1} \exp\{-b/\sigma^2\}$:

$$p(\sigma^2) \propto (\sigma^2)^{-a-1} \exp\left\{-\frac{b}{\sigma^2}\right\}$$

Κοινή Ύστερη Κατανομή

Από το Θεώρημα Bayes:

$$p(\boldsymbol{\beta}, \sigma^2 \mid \mathbf{y}, \mathbf{X}) \propto \underbrace{\ell(\boldsymbol{\beta}, \sigma^2 \mid \mathbf{y}, \mathbf{X})}_{\text{πιθανοφάνεια}} \cdot \underbrace{p(\boldsymbol{\beta} \mid \sigma^2)}_{\text{prior } \boldsymbol{\beta}} \cdot \underbrace{p(\sigma^2)}_{\text{prior } \sigma^2}$$

Πολλαπλασιάζουμε τους τρεις πυρήνες και συνενώνουμε:

$$p(\boldsymbol{\beta}, \sigma^2 \mid \mathbf{y}, \mathbf{X}) \propto (\sigma^2)^{-n/2-8-a-1} \exp\left\{-\frac{1}{2\sigma^2} \left[s^2 + (\boldsymbol{\beta} - \hat{\boldsymbol{\beta}})^\top (\mathbf{X}^\top \mathbf{X}) (\boldsymbol{\beta} - \hat{\boldsymbol{\beta}}) + \boldsymbol{\beta}^\top \mathbf{M} \boldsymbol{\beta}\right] - \frac{b}{\sigma^2}\right\}$$

Απλοποίηση Εκθέτη ως προς $\boldsymbol{\beta}$

Αναπτύσσουμε $(\boldsymbol{\beta} - \hat{\boldsymbol{\beta}})^\top (\mathbf{X}^\top \mathbf{X}) (\boldsymbol{\beta} - \hat{\boldsymbol{\beta}})$:

$$= \boldsymbol{\beta}^\top (\mathbf{X}^\top \mathbf{X}) \boldsymbol{\beta} - 2\hat{\boldsymbol{\beta}}^\top (\mathbf{X}^\top \mathbf{X}) \boldsymbol{\beta} + \hat{\boldsymbol{\beta}}^\top (\mathbf{X}^\top \mathbf{X}) \hat{\boldsymbol{\beta}}$$

Άρα:

$$(\boldsymbol{\beta} - \hat{\boldsymbol{\beta}})^\top (\mathbf{X}^\top \mathbf{X}) (\boldsymbol{\beta} - \hat{\boldsymbol{\beta}}) + \boldsymbol{\beta}^\top \mathbf{M} \boldsymbol{\beta} = \boldsymbol{\beta}^\top (\mathbf{M} + \mathbf{X}^\top \mathbf{X}) \boldsymbol{\beta} - 2\hat{\boldsymbol{\beta}}^\top (\mathbf{X}^\top \mathbf{X}) \boldsymbol{\beta} + \hat{\boldsymbol{\beta}}^\top (\mathbf{X}^\top \mathbf{X}) \hat{\boldsymbol{\beta}}$$

Ορίζουμε $\boldsymbol{\beta}^* = (\mathbf{M} + \mathbf{X}^\top \mathbf{X})^{-1} (\mathbf{X}^\top \mathbf{X}) \hat{\boldsymbol{\beta}}$ και από την 1η ταυτότητα της εκφώνησης έχουμε:

$$(\boldsymbol{\beta} - \hat{\boldsymbol{\beta}})^\top (\mathbf{X}^\top \mathbf{X}) (\boldsymbol{\beta} - \hat{\boldsymbol{\beta}}) + \boldsymbol{\beta}^\top \mathbf{M} \boldsymbol{\beta} = (\boldsymbol{\beta} - \boldsymbol{\beta}^*)^\top (\mathbf{M} + \mathbf{X}^\top \mathbf{X}) (\boldsymbol{\beta} - \boldsymbol{\beta}^*) + C$$

όπου:

$$C = \hat{\boldsymbol{\beta}}^\top (\mathbf{X}^\top \mathbf{X}) \hat{\boldsymbol{\beta}} - \hat{\boldsymbol{\beta}}^\top (\mathbf{X}^\top \mathbf{X}) (\mathbf{M} + \mathbf{X}^\top \mathbf{X})^{-1} (\mathbf{X}^\top \mathbf{X}) \hat{\boldsymbol{\beta}}$$

Παρατήρηση 1. Ο $\beta^* = (M + X^T X)^{-1} (X^T X) \hat{\beta}$ είναι **σταθμισμένος μέσος** μεταξύ της *prior mean* $\mathbf{0}$ και του *OLS* εκτιμητή $\hat{\beta}$: όσο πιο ισχυρή η *prior* (μεγάλο M), τόσο περισσότερο ο β^* τείνει προς $\mathbf{0}$, ενώ όσο πιο ασθενής (μικρό M , μεγάλο M^{-1}), τόσο $\beta^* \rightarrow \hat{\beta}$. Με $M = \frac{1}{10000} I_{16}$, ο β^* είναι πρακτικά ίσος με τον *OLS* εκτιμητή.

Από την 2η ταυτότητα της εκφώνησης:

$$(\mathbf{M} + \mathbf{X}^T \mathbf{X})^{-1} = (\mathbf{X}^T \mathbf{X})^{-1} - (\mathbf{X}^T \mathbf{X})^{-1} (\mathbf{M}^{-1} + (\mathbf{X}^T \mathbf{X})^{-1})^{-1} (\mathbf{X}^T \mathbf{X})^{-1}$$

Υπολογίζουμε $(\mathbf{X}^T \mathbf{X})(\mathbf{M} + \mathbf{X}^T \mathbf{X})^{-1}(\mathbf{X}^T \mathbf{X})$:

- Πρώτος όρος: $(\mathbf{X}^T \mathbf{X})(\mathbf{X}^T \mathbf{X})^{-1}(\mathbf{X}^T \mathbf{X}) = (\mathbf{X}^T \mathbf{X})$
- Δεύτερος όρος: $(\mathbf{X}^T \mathbf{X})(\mathbf{X}^T \mathbf{X})^{-1} (\mathbf{M}^{-1} + (\mathbf{X}^T \mathbf{X})^{-1})^{-1} (\mathbf{X}^T \mathbf{X})^{-1}(\mathbf{X}^T \mathbf{X}) = (\mathbf{M}^{-1} + (\mathbf{X}^T \mathbf{X})^{-1})^{-1}$

Άρα:

$$C = \hat{\beta}^T (\mathbf{X}^T \mathbf{X}) \hat{\beta} - \hat{\beta}^T \left[(\mathbf{X}^T \mathbf{X}) - (\mathbf{M}^{-1} + (\mathbf{X}^T \mathbf{X})^{-1})^{-1} \right] \hat{\beta}$$

$$\boxed{C = \hat{\beta}^T (\mathbf{M}^{-1} + (\mathbf{X}^T \mathbf{X})^{-1})^{-1} \hat{\beta}}$$

Δεσμευμένη Ύστερη $\beta \mid \sigma^2, \mathbf{y}, \mathbf{X}$

Η δεσμευμένη ύστερη κατανομή βρίσκεται κρατώντας μόνο ό,τι εξαρτάται από β :

$$p(\beta \mid \sigma^2, \mathbf{y}, \mathbf{X}) \propto \exp \left\{ -\frac{(\beta - \beta^*)^T (\mathbf{M} + \mathbf{X}^T \mathbf{X})(\beta - \beta^*)}{2\sigma^2} \right\}$$

Αναγνωρίζουμε πυρήνα Πολυδιάστατης Κανονικής $N_p(\mu, \Sigma)$ με $\mu = \beta^*$ και $\Sigma = \sigma^2(\mathbf{M} + \mathbf{X}^T \mathbf{X})^{-1}$:

$$\boxed{\beta \mid \sigma^2, \mathbf{y}, \mathbf{X} \sim N_{16} \left((\mathbf{M} + \mathbf{X}^T \mathbf{X})^{-1} (\mathbf{X}^T \mathbf{X}) \hat{\beta}, \sigma^2 (\mathbf{M} + \mathbf{X}^T \mathbf{X})^{-1} \right)}$$

Περιθώρια Ύστερη $\sigma^2 \mid \mathbf{y}, \mathbf{X}$

Η περιθώρια ύστερη βρίσκεται ολοκληρώνοντας ως προς β :

$$p(\sigma^2 \mid \mathbf{y}, \mathbf{X}) \propto \int p(\beta, \sigma^2 \mid \mathbf{y}, \mathbf{X}) d\beta$$

Από το θεώρημα σταθεράς κανονικοποίησης της $N_p(\mu, \Sigma)$:

$$\int \exp \left\{ -\frac{1}{2} (\beta - \mu)^T \Sigma^{-1} (\beta - \mu) \right\} d\beta = (2\pi)^{p/2} |\Sigma|^{1/2}$$

Για $p = 16$ και $\Sigma = \sigma^2(\mathbf{M} + \mathbf{X}^T \mathbf{X})^{-1}$:

$$|\Sigma|^{1/2} = (\sigma^2)^8 |\mathbf{M} + \mathbf{X}^T \mathbf{X}|^{-1/2}$$

Οπότε το ολοκλήρωμα ως προς β δίνει τον παράγοντα $(2\pi)^8 (\sigma^2)^8 |\mathbf{M} + \mathbf{X}^T \mathbf{X}|^{-1/2}$, ο οποίος ως προς σ^2 συνεισφέρει μόνο τον $(\sigma^2)^8$ (τα $(2\pi)^8$ και $|\mathbf{M} + \mathbf{X}^T \mathbf{X}|^{-1/2}$ είναι σταθερές). Άρα:

$$p(\sigma^2 \mid \mathbf{y}, \mathbf{X}) \propto (\sigma^2)^{-n/2-8-a-1} \cdot (\sigma^2)^8 \cdot \exp \left\{ -\frac{b + \frac{s^2}{2} + \frac{C}{2}}{\sigma^2} \right\} = (\sigma^2)^{-n/2-a-1} \exp \left\{ -\frac{b + \frac{s^2}{2} + \frac{C}{2}}{\sigma^2} \right\}$$

Αναγνωρίζουμε πυρήνα IG με $(\sigma^2)^{-\alpha^*-1} \exp\{-b^*/\sigma^2\}$:

$$\sigma^2 \mid \mathbf{y}, \mathbf{X} \sim IG\left(\frac{n}{2} + a, b + \frac{s^2}{2} + \frac{\hat{\boldsymbol{\beta}}^\top (\mathbf{M}^{-1} + (\mathbf{X}^\top \mathbf{X})^{-1})^{-1} \hat{\boldsymbol{\beta}}}{2}\right)$$

όπου $a = b = 0.0001$.

Παρατήρηση 2. Ο πίνακας M^{-1} είναι διαγώνιος με τιμές 10000 στη διαγώνιο, δηλαδή:

$$M^{-1} = 10000 \cdot I_{16} \implies M = \frac{1}{10000} I_{16}.$$

Αυτή η επιλογή αντιστοιχεί σε **ασθενή (diffuse) prior**: η διασπορά $\sigma^2 M^{-1} = 10000\sigma^2 I_{16}$ είναι πολύ μεγάλη, αφήνοντας τα δεδομένα να κυριαρχούν. Η απόδειξη του Ερωτήματος B ισχύει για οποιοδήποτε θετικά ορισμένο M .

Ερώτημα Γ

Χρησιμοποιούμε το WinBUGS μέσω του πακέτου R2WinBUGS για να προσομοιώσουμε τιμές από τις ύστερες κατανομές των β_j ($j = 0, \dots, 15$) και του σ^2 . Σε αντίθεση με τον Gibbs sampler του Ερωτήματος Δ που θα υλοποιήσουμε εξ ολοκλήρου στην R, εδώ αξιοποιούμε το έτοιμο λογισμικό WinBUGS που τρέχει αυτόματα τον αλγόριθμο MCMC.

Προσομοίωση Δεδομένων

Αρχικά προσομοιώνουμε τα δεδομένα σύμφωνα με την εκφώνηση. Οι πρώτες 10 επεξηγηματικές μεταβλητές προσομοιώνονται από την πολυδιάστατη Κανονική κατανομή με μέση τιμή $\mathbf{0}$ και πίνακα συνδιακύμανσης τον ταυτοτικό, ενώ οι υπόλοιπες 5 προσομοιώνονται με βάση τη σχέση:

$$X_{ij} \sim N(0.3X_{i1} + 0.5X_{i2} + 0.7X_{i3} + 0.9X_{i4} + 1.5X_{i5}, 1), \quad j = 11, \dots, 15, \quad i = 1, \dots, 50$$

Η μεταβλητή απόκρισης προσομοιώνεται ως:

$$Y_i \sim N(4 + 2X_{i1} - X_{i5} + 1.5X_{i7} + X_{i11} + 0.5X_{i13}, 2.5^2), \quad i = 1, \dots, 50$$

```

1 set.seed(123)
2 n <- 50
3
4 # Πρώτες 10 μεταβλητές από N(0, I)
5 X1 <- matrix(rnorm(n * 10), nrow = n, ncol = 10)
6
7 # Υπόλοιπες 5 μεταβλητές
8 X2 <- matrix(NA, nrow = n, ncol = 5)
9 for (j in 1:5) {
10   X2[, j] <- rnorm(n, mean = 0.3*X1[,1] + 0.5*X1[,2] +
11                     0.7*X1[,3] + 0.9*X1[,4] + 1.5*X1[,5], sd = 1)
12 }
13
14 # Πίνακας σχεδιασμού και μεταβλητή απόκρισης
15 X <- cbind(X1, X2)
16 y <- rnorm(n, mean = 4 + 2*X1[,1] - X1[,5] + 1.5*X1[,7] +
17           X2[,1] + 0.5*X2[,3], sd = 2.5)

```

Πρότερες Κατανομές

Ο πίνακας M^{-1} είναι διαγώνιος με τιμές 10000 στη διαγώνιο:

$$M^{-1} = 10000 \cdot I_{16} \implies M = \frac{1}{10000} I_{16}$$

Η prior για $\beta_j \mid \sigma^2$ έχει διασπορά $\sigma^2 \cdot 10000$, δηλαδή precision $\frac{\tau}{10000} = \tau \cdot 0.0001$, όπου $\tau = 1/\sigma^2$. Πρόκειται για **ασθενή (diffuse) prior** που αφήνει τα δεδομένα να κυριαρχούν. Οι πρότερες κατανομές είναι:

$$\beta_j \mid \tau \sim N(0, \tau^{-1} \cdot 10000), \quad j = 0, \dots, 15$$

$$\sigma^2 \sim \text{IG}(0.0001, 0.0001) \iff \tau = \frac{1}{\sigma^2} \sim \text{Gamma}(0.0001, 0.0001)$$

Παρατήρηση 3. Το WinBUGS παραμετροποιεί την κανονική κατανομή ως $\text{dnorm}(\mu, \text{precision})$. Επειδή η precision εξαρτάται από το τ (στοχαστική ποσότητα), δεν επιτρέπεται η έκφραση $\text{dnorm}(0, \text{tau} \cdot 0.0001)$ απευθείας. Αντί αυτού ορίζουμε $\text{prec_beta} \leftarrow \tau \cdot 0.0001$ ως ξεχωριστή ποσότητα.

Κώδικας WinBUGS

```
1 model {
2   prec_beta <- tau * 0.0001
3
4   beta0 ~ dnorm(0, prec_beta)
5
6   for (j in 1:15) {
7     beta[j] ~ dnorm(0, prec_beta)
8   }
9
10  tau ~ dgamma(0.0001, 0.0001)
11  sigma2 <- 1/tau
12
13  for (i in 1:n) {
14    y[i] ~ dnorm(mu[i], tau)
15    mu[i] <- beta0 + beta[1]*X[i,1] + beta[2]*X[i,2] +
16              beta[3]*X[i,3] + beta[4]*X[i,4] + beta[5]*X[i,5] +
17              beta[6]*X[i,6] + beta[7]*X[i,7] + beta[8]*X[i,8] +
18              beta[9]*X[i,9] + beta[10]*X[i,10] + beta[11]*X[i,11]
19
20    +
21              beta[12]*X[i,12] + beta[13]*X[i,13] + beta[14]*X[i,
22    ,14] +
23              beta[15]*X[i,15]
24  }
```

Εκτέλεση WinBUGS

```
1 library(R2WinBUGS)
2
3 data_bugs <- list(y = y, X = X, n = n)
4 inits <- function() list(beta0 = 0, beta = rep(0, 15), tau = 1)
```

```

5 fit_bugs <- bugs(
6   data = data_bugs,
7   inits = inits,
8   parameters.to.save = c("beta0", "beta", "sigma2"),
9   model.file = "C:/Users/Pavlina/Desktop/model.txt",
10  bugs.directory = "C:/WinBUGS14/winbugs14_full_patched/WinBUGS14/"
11  ,
12  n.chains = 1,
13  n.iter = 100000,
14  n.burnin = 10000,
15  n.thin = 1
16 )

```

Τρέχουμε συνολικά 100,000 επαναλήψεις με 10,000 burn-in, κρατώντας 90,000 δείγματα. Το burn-in επιλέχθηκε ώστε να εξασφαλιστεί ότι η αλυσίδα έχει συγκλίνει πριν αρχίσουμε να συλλέγουμε δείγματα — όπως επιβεβαιώνεται από τα διαγνωστικά γραφήματα που ακολουθούν.


Αποτελέσματα

Ο παρακάτω πίνακας παρουσιάζει τη σύγκριση των Bayesian εκτιμήσεων (posterior mean και 95% διάστημα αξιοπιστίας) με τις εκτιμήσεις της κλασικής στατιστικής (OLS) και τις πραγματικές τιμές:

Πίνακας 1: Σύγκριση πραγματικών τιμών, OLS και Bayesian εκτιμήσεων (WinBUGS)


Parameter	True Value	OLS	Bayes Mean	2.5%	97.5%
β_0	4.0	3.8012	3.8013	3.1460	4.4600
β_1	2.0	1.7534	1.7514	0.9529	2.5460
β_2	0.0	-0.1431	-0.1493	-1.1080	0.8003
β_3	0.0	-1.0082	-1.0180	-2.1720	0.1087
β_4	0.0	-1.1291	-1.1380	-2.4380	0.1351
β_5	-1.0	-1.3505	-1.3655	-3.4190	0.6225
β_6	0.0	-0.2287	-0.2313	-0.8865	0.4244
β_7	1.5	0.8680	0.8674	0.2740	1.4570
β_8	0.0	0.5856	0.5874	-0.0223	1.1920
β_9	0.0	-0.3810	-0.3828	-1.0610	0.3000
β_{10}	0.0	0.2377	0.2391	-0.4497	0.9330
β_{11}	1.0	0.5639	0.5626	-0.1196	1.2480
β_{12}	0.0	-0.0300	-0.0298	-0.6884	0.6309
β_{13}	0.5	0.6946	0.6971	0.0775	1.3090
β_{14}	0.0	0.2464	0.2513	-0.3208	0.8235
β_{15}	0.0	0.6731	0.6756	0.0264	1.3260
σ^2	6.25	5.4679	3.8725	2.6010	5.7580

Θηκογραφήματα Υστέρων Κατανομών




Σχήμα 1: Ύστερες κατανομές των συντελεστών παλινδρόμησης (WinBUGS). Τα κόκκινα διαμάντια δείχνουν τις πραγματικές τιμές, η διακεκομμένη γραμμή αντιστοιχεί στο μηδέν.


Διαγνωστικά Γραφήματα



Σχήμα 2: Trace plots για β_0 , β_1 , β_5 , β_7 και σ^2 . Όλες οι αλυσίδες κινούνται τυχαία γύρω από σταθερή τιμή χωρίς τάση ή drift, υποδηλώνοντας επιτυχή σύγκλιση του αλγορίθμου MCMC.



Σχήμα 3: Διαγράμματα αυτοσυσχέτισης. Μόνο το lag 0 είναι στατιστικά σημαντικό, ενώ για όλα τα υπόλοιπα lags η αυτοσυσχέτιση είναι πρακτικά μηδενική. Αυτό σημαίνει ότι τα δείγματα είναι σχεδόν ανεξάρτητα — ένδειξη εξαιρετικής ανάμιξης της αλυσίδας, χαρακτηριστική του Gibbs sampler.



Σχήμα 4: Running quantiles (2.5%, 50%, 97.5%) για β_0 , β_1 , β_5 , β_7 και σ^2 . Τα ποσοστημόρια σταθεροποιούνται μέσα στις πρώτες ~ 5000 επαναλήψεις για όλες τις παραμέτρους, επιβεβαιώνοντας την επαρκή σύγκλιση και ότι το burn-in των 10000 επαναλήψεων είναι συντηρητικά επαρκές.

Σχόλια

Σύγκριση Bayesian και OLS εκτιμήσεων: Οι Bayesian εκτιμήσεις (posterior mean) είναι πολύ κοντά στις OLS εκτιμήσεις. Αυτό είναι αναμενόμενο: με $M^{-1} = 10000 \cdot I_{16}$ η prior είναι εξαιρετικά διάχυτη και τα δεδομένα κυριαρχούν πλήρως.

Ποιες μεταβλητές αφαιρούμε; Χρησιμοποιούμε ως κριτήριο το 95% διάστημα αξιοπιστίας: αφαιρούμε τις μεταβλητές για τις οποίες το διάστημα περιέχει το μηδέν.

- **Κρατάμε:** $\beta_0, \beta_1, \beta_7$
- **Αφαιρούμε:** $\beta_2, \beta_3, \dots, \beta_6, \beta_8, \dots, \beta_{15}$

Παρατηρούμε ότι ο β_5 (πραγματική τιμή -1) και οι β_{11}, β_{13} (πραγματικές τιμές 1 και 0.5) αφαιρούνται παρόλο που είναι μη μηδενικοί. Αυτό οφείλεται σε δύο αιτίες:

1. **Πολυσυγγραμμικότητα:** Οι μεταβλητές $X_{11} \dots X_{15}$ εξαρτώνται γραμμικά από τις $X_1 \dots X_5$, με αποτέλεσμα μεγάλη αβεβαιότητα στις εκτιμήσεις των αντίστοιχων συντελεστών.
2. **Μικρό SNR:** Η επίδραση του $\beta_5 = -1$ καλύπτεται από τη διακύμανση $\sigma^2 = 6.25$ και την πολυσυγγραμμικότητα με τις $X_{11} \dots X_{15}$.

Είναι οι πραγματικές τιμές στο κέντρο των υστέρων κατανομών; Από τον πίνακα και τα θηκογραφήματα παρατηρούμε ότι:

- Για τους β_0 και β_1 οι πραγματικές τιμές (4 και 2) βρίσκονται κοντά στο κέντρο των υστέρων κατανομών.
- Για τον β_7 η πραγματική τιμή (1.5) βρίσκεται ελαφρώς εκτός κέντρου (posterior mean = 0.87), γεγονός που αντικατοπτρίζει τη δυσκολία εκτίμησης λόγω πολυσυγγραμμικότητας.
- Για τους υπόλοιπους συντελεστές με πραγματική τιμή 0, τα κέντρα των κατανομών είναι κοντά στο μηδέν, αν και με σημαντική αβεβαιότητα.

Ερώτημα Δ

Σε αντίθεση με το Ερώτημα Γ όπου χρησιμοποιήσαμε το έτοιμο λογισμικό WinBUGS, εδώ υλοποιούμε εξ ολοκλήρου τον αλγόριθμο Gibbs Sampler στην R, βασιζόμενοι στις αναλυτικές εκφράσεις των πλήρων δεσμευμένων κατανομών που αποδείξαμε στο Ερώτημα Β.

Θεωρητικό Υπόβαθρο

Ο αλγόριθμος Gibbs Sampler είναι μέθοδος MCMC που προσομοιώνει τιμές από μια πολυδιάστατη κατανομή, δειγματολογώντας εναλλάξ από τις πλήρεις δεσμευμένες κατανομές (full conditional distributions) κάθε παραμέτρου. Στο πρόβλημά μας, από το Ερώτημα Β έχουμε:

Βήμα 1 — Δειγματοληψία $\beta \mid \sigma^2, \mathbf{y}, X$:

$$\beta \mid \sigma^2, \mathbf{y}, X \sim N_{16}(\beta^*, \sigma^2(M + X^\top X)^{-1})$$

όπου $\beta^* = (M + X^\top X)^{-1}(X^\top X)\hat{\beta}$.

Βήμα 2 — Δειγματοληψία $\sigma^2 \mid \beta, \mathbf{y}, X$:

$$\sigma^2 \mid \beta, \mathbf{y}, X \sim \text{IG}\left(\frac{n+p}{2} + a, b + \frac{\|\mathbf{y} - X\beta\|^2 + \beta^\top M\beta}{2}\right)$$

Με $M = \frac{1}{10000}I_{16}$, ο όρος $\beta^\top M\beta = \frac{1}{10000} \sum_j \beta_j^2$ είναι πρακτικά αμελητέος, επιβεβαιώνοντας ότι η prior είναι ασθενής.

Παρατήρηση 4. Οι δύο αυτές κατανομές εναλλάσσονται σε κάθε επανάληψη $t = 1, \dots, T$, παράγοντας μια αλυσίδα Markov που συγκλίνει στην από κοινού ύστερη κατανομή $p(\beta, \sigma^2 \mid \mathbf{y}, X)$.

Κώδικας R --- Υλοποίηση Gibbs Sampler

```
1 library(mvtnorm)
2
3 gibbs_bayes_lm <- function(X, y, M_diag = 1/10000,
4                             n_iter = 20000, burn_in = 5000) {
5   n <- nrow(X)      # αριθμός παρατηρήσεων (50)
6   p <- ncol(X)      # αριθμός παραμέτρων (16)
7   a <- 0.0001
```

```

8   b <- 0.0001
9
10  # M = (1/10000)*I_p
11  M <- diag(M_diag, p)
12
13  # Σταθερές ποσότητες από Ερώτημα B
14  XtX <- t(X) %*% X
15  Xty <- t(X) %*% y
16  V_beta <- solve(M + XtX) # (M + X'X)^{-1}
17  beta_star <- as.numeric(V_beta %*% Xty) # posterior mean
18
19  # Αρχικοποίηση
20  beta_cur <- rep(0, p)
21  sigma2_cur <- 1.0
22
23  # Αποθήκευση δειγμάτων
24  beta_samples <- matrix(0, nrow = n_iter, ncol = p)
25  sigma2_samples <- numeric(n_iter)
26
27  for (t in 1:n_iter) {
28
29    # Βήμα 1: beta | sigma2, y, X
30    Sigma_beta <- sigma2_cur * V_beta
31    beta_cur <- as.numeric(rmvnorm(1, mean = beta_star,
32                                   sigma = Sigma_beta))
33    beta_samples[t, ] <- beta_cur
34
35    # Βήμα 2: sigma2 | beta, y, X
36    resid <- as.numeric(y - X %*% beta_cur)
37    #  $\beta' \beta M = (1/10000) * \sum \beta^2$  αφού  $M = (1/10000) * I$ 
38    beta_TMbeta <- M_diag * sum(beta_cur^2)
39    shape_sig <- (n + p)/2 + a
40    rate_sig <- b + 0.5*(sum(resid^2) + beta_TMbeta)
41    sigma2_cur <- 1/rgamma(1, shape=shape_sig, rate=rate_sig)
42    sigma2_samples[t] <- sigma2_cur
43  }
44
45  keep <- (burn_in + 1):n_iter
46  return(list(
47    beta = beta_samples[keep, ],
48    sigma2 = sigma2_samples[keep]
49  ))
50 }
51
52 # Εκτέλεση
53 set.seed(123)
54 X_full <- cbind(1, X) # προσθήκη intercept
55
56 gibbs_results <- gibbs_bayes_lm(
57   X = X_full,
58   y = y,

```

```

59 M_diag = 1/10000,
60 n_iter = 20000,
61 burn_in = 5000
62 )

```


Τρέχουμε 20,000 επαναλήψεις με 5,000 burn-in, κρατώντας 15,000 δείγματα. Το burn-in επιλέχθηκε βάσει των running quantiles που δείχνουν σταθεροποίηση μέσα στις πρώτες ~1000--2000 επαναλήψεις — άρα το burn-in των 5000 είναι συντηρητικά ασφαλές.

Αποτελέσματα

Πίνακας 2: Σύγκριση Gibbs Sampler με OLS και WinBUGS


Parameter	True	OLS	Gibbs Mean	Gibbs SD	2.5%	97.5%
β_0	4.0	3.8012	3.7995	0.3373	3.1321	4.4622
β_1	2.0	1.7534	1.7518	0.4081	0.9454	2.5517
β_2	0.0	-0.1431	-0.1433	0.4837	-1.1046	0.7958
β_3	0.0	-1.0082	-1.0095	0.5841	-2.1531	0.1446
β_4	0.0	-1.1291	-1.1347	0.6629	-2.4524	0.1807
β_5	-1.0	-1.3505	-1.3521	1.0287	-3.3794	0.6852
β_6	0.0	-0.2287	-0.2239	0.3313	-0.8743	0.4240
β_7	1.5	0.8680	0.8674	0.3024	0.2785	1.4658
β_8	0.0	0.5856	0.5858	0.3077	-0.0184	1.1970
β_9	0.0	-0.3810	-0.3815	0.3468	-1.0704	0.3081
β_{10}	0.0	0.2377	0.2419	0.3519	-0.4528	0.9458
β_{11}	1.0	0.5639	0.5612	0.3509	-0.1268	1.2497
β_{12}	0.0	-0.0300	-0.0291	0.3367	-0.6873	0.6331
β_{13}	0.5	0.6946	0.6983	0.3105	0.0819	1.3040
β_{14}	0.0	0.2464	0.2458	0.2938	-0.3337	0.8243
β_{15}	0.0	0.6731	0.6744	0.3308	0.0294	1.3231
σ^2	6.25	5.4679	3.8646	--	--	--

Θηκογραφήματα Υστέρων Κατανομών




Σχήμα 5: Ύστερες κατανομές των συντελεστών παλινδρόμησης (Gibbs Sampler). Τα κόκκινα διαμάντια δείχνουν τις πραγματικές τιμές, η διακεκομμένη γραμμή αντιστοιχεί στο μηδέν.


Διαγνωστικά Γραφήματα



Σχήμα 6: Trace plots για β_0 , β_1 , β_5 , β_7 και σ^2 . Όλες οι αλυσίδες κινούνται τυχαία γύρω από σταθερή τιμή χωρίς τάση ή drift, υποδηλώνοντας επιτυχή σύγκλιση.



Σχήμα 7: Διαγράμματα αυτοσυσχέτισης. Για τους β_j η αυτοσυσχέτιση είναι πρακτικά μηδενική από το lag 1. Για το σ^2 υπάρχει μικρή αυτοσυσχέτιση στα πρώτα 2--3 lags, αναμενόμενη και αποδεκτή. Συνολικά τα δείγματα είναι σχεδόν ανεξάρτητα — πλεονέκτημα του Gibbs sampler έναντι του Metropolis-Hastings.



Σχήμα 8: Running quantiles (2.5%, 50%, 97.5%). Τα ποσοστημόρια σταθεροποιούνται μέσα στις πρώτες ~1000--2000 επαναλήψεις, επιβεβαιώνοντας ότι το burn-in των 5000 είναι συντηρητικά επαρκές.

Σχόλια και Συμπεράσματα

Σύγκριση Gibbs Sampler με OLS: Οι ύστερες μέσες τιμές του Gibbs Sampler συμπίπτουν σχεδόν απόλυτα με τις εκτιμήσεις OLS. Αυτό είναι αναμενόμενο: με $M^{-1} = 10000 \cdot I_{16}$ η prior είναι εξαιρετικά διάχυτη και τα δεδομένα κυριαρχούν πλήρως.

Σύγκριση Gibbs Sampler με WinBUGS: Οι εκτιμήσεις του Gibbs Sampler συμφωνούν άριστα με αυτές του WinBUGS, επιβεβαιώνοντας την ορθότητα της υλοποίησης. Οι μικρές διαφορές οφείλονται στον τυχαίο χαρακτήρα της δειγματοληψίας MCMC.

Εκτίμηση σ^2 : Και οι δύο Bayesian μέθοδοι (Gibbs: 3.86, WinBUGS: 3.87) δίνουν παρόμοιες εκτιμήσεις, αλλά χαμηλότερες από την πραγματική τιμή $\sigma^2 = 6.25$. Αυτό οφείλεται στη μικρή τιμή $n = 50$ σε συνδυασμό με $p = 15$ μεταβλητές — το μοντέλο έχει σχετικά μικρό αριθμό βαθμών ελευθερίας.

Πλεονέκτημα Gibbs έναντι Metropolis-Hastings: Όπως φαίνεται από τα ACF plots, ο Gibbs sampler παράγει σχεδόν ανεξάρτητα δείγματα (μηδενική αυτοσυσχέτιση από lag 1), σε αντίθεση με τον Metropolis-Hastings (Άσκηση 4) που εμφανίζει σημαντική αυτοσυσχέτιση. Αυτό είναι το κύριο πλεονέκτημα του Gibbs όταν οι πλήρεις δεσμευμένες κατανομές είναι αναλυτικά γνωστές.

Σύγκριση με Αναλυτικά Αποτελέσματα Ερωτήματος Β: Από το Ερώτημα Β, η αναλυτική ύστερη μέση τιμή του β είναι:

$$\beta^* = (M + X^\top X)^{-1} (X^\top X) \hat{\beta}$$

Με $M = \frac{1}{10000} I_{16}$, ο πίνακας M είναι πρακτικά μηδενικός σε σχέση με τον $X^\top X$, οπότε:

$$\beta^* = \left(\frac{1}{10000} I + X^\top X \right)^{-1} (X^\top X) \hat{\beta} \approx (X^\top X)^{-1} (X^\top X) \hat{\beta} = \hat{\beta}$$

Άρα η αναλυτική posterior mean συμπίπτει σχεδόν ακριβώς με τον OLS εκτιμητή. Αυτό επιβεβαιώνεται εμπειρικά: οι posterior means του Gibbs sampler (π.χ. $\beta_0 = 3.7995$, $\beta_1 = 1.7518$) συμφωνούν άριστα τόσο με τον OLS (3.8012, 1.7534) όσο και με την αναλυτική τιμή του Β.

Επιπλέον, η αναλυτική ύστερη κατανομή του σ^2 από το Ερώτημα Β είναι:

$$\sigma^2 \mid \mathbf{y}, X \sim \text{IG} \left(\frac{n}{2} + a, b + \frac{s^2}{2} + \frac{\hat{\beta}^\top (M^{-1} + (X^\top X)^{-1})^{-1} \hat{\beta}}{2} \right)$$

με αναμενόμενη τιμή $\frac{b^*}{a^*-1}$ όπου $a^* = n/2 + a$ και b^* ο αντίστοιχος ρυθμός. Η εκτίμηση του Gibbs (3.86) συμφωνεί με αυτή την αναλυτική τιμή, επιβεβαιώνοντας την ορθότητα της υλοποίησης.

Άσκηση 2

Εισαγωγή - Βασικές Έννοιες

Κατανομή Poisson

Η κατανομή Poisson χρησιμοποιείται για να μοντελοποιήσουμε τον αριθμό γεγονότων που συμβαίνουν σε ένα συγκεκριμένο χρονικό διάστημα. Αν $X \sim \text{Poisson}(\lambda)$, η συνάρτηση πιθανότητας είναι:

$$P(X = x \mid \lambda) = \frac{e^{-\lambda} \lambda^x}{x!}, \quad x = 0, 1, 2, \dots$$

όπου $\lambda > 0$ είναι ο μέσος ρυθμός εμφάνισης γεγονότων.

Επαρκές Στατιστικό

Για n ανεξάρτητες παρατηρήσεις $X_1, \dots, X_n \sim \text{Poisson}(\lambda)$, το επαρκές στατιστικό είναι το άθροισμα:

$$T = \sum_{i=1}^n X_i \sim \text{Poisson}(n\lambda)$$

Στο πρόβλημά μας: $n = 10$ ημέρες και $T = 35$ συνολικά σφάλματα, άρα $T \sim \text{Poisson}(10\lambda)$.

Ερώτημα Α

Διατύπωση Ελέγχου

Θέλουμε να ελέγξουμε:

$$H_0 : \lambda = 2 \quad \text{έναντι} \quad H_1 : \lambda \neq 2$$

Θεωρούμε ότι οι δύο υποθέσεις είναι εξίσου πιθανές a priori:

$$P(H_0) = P(H_1) = 0.5$$

Περιθώρια Πιθανοφάνεια κάτω από H_0

Κάτω από την H_0 , το $\lambda = 2$ είναι γνωστό, άρα $T \sim \text{Poisson}(10 \cdot 2) = \text{Poisson}(20)$:

$$P(T = 35 | H_0) = \frac{e^{-20} \cdot 20^{35}}{35!}$$


Περιθώρια Πιθανοφάνεια κάτω από H_1

Κάτω από την H_1 , το λ είναι άγνωστο με prior $\lambda \sim \text{Gamma}(2, 1)$ με πυκνότητα:

$$p(\lambda) = \frac{1^2}{\Gamma(2)} \lambda^{2-1} e^{-\lambda} = \lambda e^{-\lambda}, \quad \lambda > 0$$

Η prior $\lambda \sim \text{Gamma}(2, 1)$ αντιπροσωπεύει ασθενή πεποίθηση ότι ο ρυθμός κυμαίνεται γύρω από το 2 για τους εξής λόγους:

- Μέση τιμή: $E[\lambda] = \frac{2}{1} = 2$, που συμπίπτει με την τιμή της μηδενικής υπόθεσης $\lambda_0 = 2$.
- Διασπορά: $\text{Var}[\lambda] = \frac{2}{1^2} = 2$, που είναι αρκετά μεγάλη σχετικά με τη μέση τιμή, αντικατοπτρίζοντας σημαντική αβεβαιότητα γύρω από το 2.
- Το γράφημα παρακάτω δείχνει ότι η κατανομή είναι αρκετά διάχυτη, δηλαδή δεν συγκεντρώνεται στενά γύρω από το 2 αλλά καλύπτει ένα ευρύ φάσμα τιμών.



Σχήμα 9: Η πρότερη κατανομή $\text{Gamma}(2, 1)$ για το λ . Η κόκκινη διακεκομμένη γραμμή δείχνει τη μέση τιμή $E[\lambda] = 2$ (μηδενική υπόθεση), ενώ η πράσινη δείχνει τον εμπειρικό μέσο $\bar{x} = 3.5$. Η μεγάλη διασπορά ($\text{Var}[\lambda] = 2$) αντικατοπτρίζει την ασθενή πεποίθηση γύρω από το $\lambda = 2$. Η περιθώρια πιθανοφάνεια κάτω από H_1 υπολογίζεται ολοκληρώνοντας ως προς λ :

$$\begin{aligned} P(T = 35 | H_1) &= \int_0^\infty P(T = 35 | \lambda) \cdot p(\lambda) d\lambda \\ &= \int_0^\infty \frac{e^{-10\lambda} (10\lambda)^{35}}{35!} \cdot \lambda e^{-\lambda} d\lambda = \frac{10^{35}}{35!} \int_0^\infty \lambda^{36} e^{-11\lambda} d\lambda \end{aligned}$$

Χρησιμοποιούμε τον τύπο:

$$\int_0^\infty \lambda^k e^{-c\lambda} d\lambda = \frac{\Gamma(k+1)}{c^{k+1}}$$

με $k = 36$ και $c = 11$:

$$\int_0^\infty \lambda^{36} e^{-11\lambda} d\lambda = \frac{\Gamma(37)}{11^{37}} = \frac{36!}{11^{37}}$$

Επομένως:

$$P(T = 35 | H_1) = \frac{10^{35}}{35!} \cdot \frac{36!}{11^{37}} = \frac{10^{35} \cdot 36}{11^{37}}$$

Παράγοντας Bayes και Posterior Odds

Ο παράγοντας Bayes της H_1 έναντι της H_0 είναι:

$$BF_{10} = \frac{P(T = 35 | H_1)}{P(T = 35 | H_0)} = \frac{\frac{10^{35} \cdot 36}{11^{37}}}{\frac{e^{-20} \cdot 20^{35}}{35!}} = \frac{10^{35} \cdot 36 \cdot 35! \cdot e^{-20}}{11^{37} \cdot 20^{35}}$$

Επειδή οι prior πιθανότητες είναι ίσες ($P(H_0) = P(H_1) = 0.5$), ο ύστερος λόγος των συμπληρωματικών πιθανοτήτων (posterior odds) συνδέεται με τον παράγοντα Bayes ως εξής:

$$PO_{10} = \frac{P(H_1 | T)}{P(H_0 | T)} = BF_{10} \times \frac{P(H_1)}{P(H_0)} = 15.45 \times \frac{0.5}{0.5} = BF_{10} = 15.45$$

Δηλαδή, μετά την παρατήρηση $T = 35$, η H_1 είναι 15.45 φορές πιο πιθανή από την H_0 . Υπολογίζουμε αριθμητικά στην R:

```
1 # Περιθώρια πιθανοφάνεια κάτω από H0
2 # T ~ Poisson(10*2) = Poisson(20)
3 log_m0 <- dpois(35, lambda = 20, log = TRUE)
4
5 # Περιθώρια πιθανοφάνεια κάτω από H1
6 # Αναλυτικά: P(T=35|H1) = 10^35 * 36 / 11^37
7 log_m1 <- 35*log(10) + log(36) - 37*log(11)
8
9 # Bayes Factor BF10
10 BF10 <- exp(log_m1 - log_m0)
11 cat("Bayes Factor BF10:", round(BF10, 4), "\n")
12 # Bayes Factor BF10: 15.4471
13
14 # Posterior Odds: ίσες prior πιθανότητες
15 P010 <- BF10
16 cat("Posterior Odds P010:", round(P010, 4), "\n")
17 # Posterior Odds P010: 15.4471
```

Συμπέρασμα

Ο $BF_{10} = 15.45$ σημαίνει ότι τα δεδομένα είναι 15.45 φορές πιο πιθανά κάτω από την H_1 απ' ό,τι κάτω από την H_0 .

Χρησιμοποιώντας την κλίμακα Jeffreys για την ερμηνεία:

BF_{10}	Ερμηνεία
1 – 3	Αμελητέα υπεροχή H_1
3 – 10	Μέτρια υπεροχή H_1
10 – 30	Ισχυρή υπεροχή H_1
> 30	Πολύ ισχυρή υπεροχή H_1

Το γεγονός ότι $BF_{10} = PO_{10} = 15.45$ δείχνει ισχυρή υπεροχή της H_1 έναντι της H_0 . Απορρίπτουμε την $H_0 : \lambda = 2$ και συμπεραίνουμε ότι ο πραγματικός ρυθμός σφαλμάτων διαφέρει σημαντικά από 2. Αυτό είναι λογικό γιατί παρατηρήσαμε 35 σφάλματα σε 10 ημέρες, δηλαδή εμπειρικός μέσος ρυθμός $\bar{x} = 35/10 = 3.5$ σφάλματα/ημέρα, που απέχει αρκετά από το $\lambda_0 = 2$.

Ερώτημα Β

Βήμα 1: Ύστερη Κατανομή του λ κάτω από H_1

Η Gamma κατανομή είναι *συζυγής prior* (conjugate prior) για την Poisson likelihood, δηλαδή η ύστερη κατανομή ανήκει στην ίδια οικογένεια με την prior.

Έχουμε:

- Prior: $\lambda \sim \text{Gamma}(\alpha, \beta) = \text{Gamma}(2, 1)$ με πυρήνα $p(\lambda) \propto \lambda^{\alpha-1} e^{-\beta\lambda} = \lambda e^{-\lambda}$
- Likelihood: $T = \sum_{i=1}^n x_i \sim \text{Poisson}(n\lambda)$ με πυρήνα $P(T | \lambda) \propto \lambda^T e^{-n\lambda} = \lambda^{35} e^{-10\lambda}$

Η ύστερη κατανομή είναι ανάλογη του γινομένου likelihood $\times$ prior:

$$p(\lambda | T) \propto \lambda^{35} e^{-10\lambda} \cdot \lambda e^{-\lambda} = \lambda^{36} e^{-11\lambda}$$

Αναγνωρίζουμε πυρήνα *Gamma* με παραμέτρους:


$$\alpha^* = 36 + 1 = 37, \quad \beta^* = 11$$

Άρα ο γενικός κανόνας ενημέρωσης είναι:

$$\text{Gamma}(\alpha, \beta) \xrightarrow{T, n} \text{Gamma}(\alpha + T, \beta + n)$$

και στο πρόβλημά μας:

$$\lambda | T \sim \text{Gamma}(2 + 35, 1 + 10) = \text{Gamma}(37, 11)$$



Σχήμα 10: Σύγκριση prior $Gamma(2, 1)$ και posterior $Gamma(37, 11)$ για το λ . Η κόκκινη διακεκομμένη γραμμή δείχνει τη μέση τιμή της prior ($E[\lambda] = 2$), η μπλε δείχνει τη μέση τιμή της posterior ($E[\lambda | T] = 3.36$) και η πράσινη τον MLE ($\lambda = 3.5$). Παρατηρούμε ότι η posterior είναι πολύ πιο συγκεντρωμένη από την prior, αντικατοπτρίζοντας την ενημέρωση της πεποίθησής μας μετά την παρατήρηση $T = 35$ σφαλμάτων σε $n = 10$ ημέρες.

Βήμα 2: Ύστερη Προβλεπτική Κατανομή της X_{11}

Η ύστερη προβλεπτική κατανομή της νέας παρατήρησης X_{11} βρίσκεται ολοκληρώνοντας ως προς λ :

$$\begin{aligned} P(X_{11} = x | T) &= \int_0^\infty P(X_{11} = x | \lambda) \cdot p(\lambda | T) d\lambda \\ &= \int_0^\infty \frac{e^{-\lambda} \lambda^x}{x!} \cdot \frac{11^{37}}{\Gamma(37)} \lambda^{36} e^{-11\lambda} d\lambda = \frac{11^{37}}{x! \cdot \Gamma(37)} \int_0^\infty \lambda^{x+36} e^{-12\lambda} d\lambda \end{aligned}$$

Χρησιμοποιούμε τον τύπο $\int_0^\infty \lambda^k e^{-c\lambda} d\lambda = \frac{\Gamma(k+1)}{c^{k+1}}$ με $k = x + 36$ και $c = 12$:

$$P(X_{11} = x | T) = \frac{11^{37}}{x! \cdot \Gamma(37)} \cdot \frac{\Gamma(x+37)}{12^{x+37}} = \frac{\Gamma(x+37)}{\Gamma(37) \cdot x!} \cdot \left(\frac{11}{12}\right)^{37} \cdot \left(\frac{1}{12}\right)^x$$

Αναγνωρίζουμε την *Αρνητική Διωνυμική κατανομή* (Negative Binomial):

$$X_{11} | T \sim \text{NegBin}\left(r = 37, p = \frac{11}{12}\right)$$

Βήμα 3: Μέση Τιμή και Διασπορά

Για $\text{NegBin}(r, p)$ με $r = 37$ και $p = 11/12$:

$$E[X_{11} | T] = \frac{r(1-p)}{p} = \frac{37 \cdot \frac{1}{12}}{\frac{11}{12}} = \frac{37}{11} \approx 3.364$$

$$Var[X_{11} | T] = \frac{r(1-p)}{p^2} = \frac{37 \cdot \frac{1}{12}}{\left(\frac{11}{12}\right)^2} = \frac{37 \cdot 12}{121} = \frac{444}{121} \approx 3.669$$

Βήμα 4: Σύγκριση με Κλασική Στατιστική

Στην κλασική στατιστική, εκτιμούμε λ με τον MLE:

$$\hat{\lambda}_{MLE} = \bar{x} = \frac{T}{n} = \frac{35}{10} = 3.5$$

Η προβλεπτική κατανομή κάτω από κλασική στατιστική είναι:

$$X_{11} | \hat{\lambda} \sim Poisson(3.5)$$

με $E[X_{11}] = 3.5$ και $Var[X_{11}] = 3.5$.

Συγκρίνουμε τα δύο αποτελέσματα:

	Κατανομή	Μέση Τιμή	Διασπορά
Bayesian	$NegBin(37, 11/12)$	$37/11 \approx 3.364$	≈ 3.669
Κλασική	$Poisson(3.5)$	3.5	3.5

Παρατηρούμε ότι:

- Η Bayesian μέση τιμή (3.364) είναι μικρότερη από την κλασική (3.5) γιατί η prior $Gamma(2, 1)$ με μέση τιμή 2 "τραβάει" την εκτίμηση προς τα κάτω.
- Η Bayesian διασπορά (3.669) είναι μεγαλύτερη από την κλασική (3.5) γιατί ενσωματώνει και την αβεβαιότητα για την παράμετρο λ , ενώ η κλασική αντιμετωπίζει το λ ως γνωστό.

Κάποια παραπάνω σχόλια

Αποσύνθεση Bayesian Διασποράς:

Η μεγαλύτερη Bayesian διασπορά δεν είναι τυχαία, αποτελεί γενικό θεωρητικό αποτέλεσμα. Η Bayesian προβλεπτική διασπορά αποσυντίθεται ως:

$$Var[X_{11} | T] = \underbrace{E[\lambda | T]}_{\text{διασπορά Poisson}} + \underbrace{Var[\lambda | T]}_{\text{αβεβαιότητα για } \lambda}$$

Υπολογίζουμε:

- $E[\lambda | T] = \frac{37}{11} \approx 3.364$ (αντιστοιχεί στη διασπορά μιας $Poisson(3.364)$)
- $Var[\lambda | T] = \frac{37}{11^2} = \frac{37}{121} \approx 0.306$ (αβεβαιότητα για το λ)

Άρα:

$$Var[X_{11} | T] = 3.364 + 0.306 = 3.669$$

Η κλασική στατιστική αντιμετωπίζει το λ ως γνωστό ($\hat{\lambda} = 3.5$) και αγνοεί την αβεβαιότητά του, οπότε η διασπορά είναι απλώς $Var[X_{11}] = 3.5$. Η Bayesian προσέγγιση είναι πιο συντηρητική και ρεαλιστική γιατί ενσωματώνει και αυτή την αβεβαιότητα.

Σύγκριση $P(X_{11} > 5)$:

```

1 # Κλασική πιθανότητα  $P(X_{11} > 5 \mid \lambda_{\text{mle}} = 3.5)$ 
2 prob_gt5_class <- 1 - ppois(5, lambda = lambda_mle)
3 # prob_gt5_class = 0.1424
4
5 # Αποσύνθεση Bayesian διασποράς
6 #  $\text{Var}[X_{11}|T] = E[\lambda|T] + \text{Var}[\lambda|T]$ 
7 E_lambda_post <- alpha_post / beta_post # = 37/11 = 3.3636
8 Var_lambda_post <- alpha_post / beta_post^2 # = 37/121 = 0.3058
9
10 # Επαλήθευση:  $E[\lambda|T] + \text{Var}[\lambda|T] = \text{Var}[X_{11}|T]$ 
11 # 3.3636 + 0.3058 = 3.6694 = Var_bayes

```

	Bayesian	Κλασική
$P(X_{11} > 5)$	0.1336	0.1424

Η κλασική στατιστική δίνει ελαφρώς υψηλότερη πιθανότητα (0.1424) έναντι της Bayesian (0.1336), γεγονός που συνάδει με τη μεγαλύτερη μέση τιμή της κλασικής (3.5 έναντι 3.364). Η διαφορά είναι μικρή λόγω της ασθενούς prior που χρησιμοποιήσαμε.

Βήμα 5: $P(X_{11} > 5 \mid T)$

Η ύστερη πιθανότητα η 11η παρατήρηση να έχει τιμή άνω του 5:

$$P(X_{11} > 5 \mid T) = 1 - P(X_{11} \leq 5 \mid T)$$

Υπολογίζουμε στην R:

```

1 # Παράμετροι ύστερης προβλεπτικής  $X_{11}|T \sim \text{NegBin}(r=37, p=11/12)$ 
2 r <- 37
3 p <- 11/12
4
5 # Μέση τιμή και διασπορά Bayesian
6 E_bayes <- r*(1-p)/p # = 37/11 = 3.3636
7 Var_bayes <- r*(1-p)/p^2 # = 444/121 = 3.6694
8
9 # Μέση τιμή και διασπορά Κλασικής (MLE)
10 lambda_mle <- 35/10 # = 3.5
11 E_class <- lambda_mle # = 3.5
12 Var_class <- lambda_mle # = 3.5
13
14 #  $P(X_{11} > 5 \mid T) = 1 - P(X_{11} \leq 5 \mid T)$ 
15 prob_gt5 <- 1 - pnbinom(5, size = r, prob = p)
16 # prob_gt5 = 0.1336


```

Άρα:

$$P(X_{11} > 5 \mid T) = 1 - P(X_{11} \leq 5 \mid T) \approx 0.1336$$

Υπάρχει δηλαδή περίπου 13.36% πιθανότητα η 11η παρατήρηση να υπερβεί το 5.

Γράφημα Ύστερης Προβλεπτικής Κατανομής



Σχήμα 11: Ύστερη προβλεπτική κατανομή της X_{11} : Bayesian ($NegBin(37, 11/12)$) vs Κλασική ($Poisson(3.5)$). Η κόκκινη διακεκομμένη γραμμή δείχνει το όριο $X_{11} = 5$, δεξιά του οποίου η πιθανότητα είναι 13.36%.

Συνολικό Συμπέρασμα

Συνοψίζοντας, η Bayesian προβλεπτική κατανομή $NegBin(37, 11/12)$ διαφέρει από την κλασική $Poisson(3.5)$ σε τρία επίπεδα:

- Η μέση τιμή (3.364 vs 3.5) είναι μικρότερη λόγω της επίδρασης της prior.
- Η διασπορά (3.669 vs 3.5) είναι μεγαλύτερη γιατί ενσωματώνει την αβεβαιότητα για το λ .
- Η πιθανότητα $P(X_{11} > 5)$ είναι μικρότερη (0.1336 vs 0.1424) συνεπώς με τη μικρότερη μέση τιμή.

Οι διαφορές είναι μικρές λόγω της ασθενούς prior που χρησιμοποιήσαμε — με ισχυρότερη prior οι διαφορές θα ήταν μεγαλύτερες.

Άσκηση 3

Περιγραφή Δεδομένων

Χρησιμοποιούμε το `esoph` dataset που είναι ενσωματωμένο στην R και προέρχεται από μελέτη περίπτωσης-ελέγχου (Breslow & Day, 1980) για τον καρκίνο του οισοφάγου στη Γαλλία. Εστιάζουμε στην ηλικιακή ομάδα 45-54 ετών.

Οι μεταβλητές που χρησιμοποιούμε είναι:

- **ncases**: αριθμός ασθενών με καρκίνο οισοφάγου — η μεταβλητή απόκρισης
- **alcgp**: κατηγορία κατανάλωσης αλκοόλ — η επεξηγηματική μεταβλητή με 4 επίπεδα:
 - dose=1: 0--39g/day (χαμηλή κατανάλωση)
 - dose=2: 40--79g/day (μέτρια κατανάλωση)
 - dose=3: 80--119g/day (υψηλή κατανάλωση)
 - dose=4: 120+g/day (πολύ υψηλή κατανάλωση)

Πίνακας 3: Δεδομένα ανά κατηγορία κατανάλωσης αλκοόλ (ηλικιακή ομάδα 45-54)

Κατηγορία	Ασθενείς	Σύνολο	Αναλογία
0--39g/day	1	78	0.013
40--79g/day	20	81	0.247
80--119g/day	12	39	0.308
120+g/day	13	15	0.867

Παρατηρείται καθαρή αύξουσα τάση: όσο αυξάνεται η κατανάλωση αλκοόλ, αυξάνεται σημαντικά η πιθανότητα καρκίνου (1.3% → 24.7% → 30.8% → 86.7%).

Θεωρητικό Υπόβαθρο

Ο αριθμός ασθενών Y_i στην κατηγορία i ακολουθεί τη Διωνυμική κατανομή:

$$Y_i \sim \text{Binomial}(n_i, p_i), \quad i = 1, 2, 3, 4$$

όπου n_i ο συνολικός αριθμός ατόμων και p_i η πιθανότητα καρκίνου στην κατηγορία i .

Πρότερες Κατανομές (Priors)

Η εκφώνηση ζητά για **μία μόνο κατηγορία** να εισαχθεί πληροφορία από παλαιότερη μελέτη. Επιλέγουμε την κατηγορία **dose=1 (0--39g/day)** ως κατηγορία αναφοράς, για την οποία υποθέτουμε ότι σε παλαιότερη μελέτη παρατηρήθηκαν **2 cases σε 40 συνολικά** άτομα. Η πληροφορία αυτή εισάγεται μέσω της συζυγούς Beta prior:

$$p_1 \sim \text{Beta}(2, 38)$$

με $E[p_1] = \frac{2}{40} = 0.05$ και $\text{Var}[p_1] = \frac{2 \cdot 38}{40^2 \cdot 41} \approx 0.0011$ — αντικατοπτρίζει την πεποίθηση ότι η πιθανότητα καρκίνου για χαμηλή κατανάλωση αλκοόλ είναι χαμηλή (~ 5%).

Για τις υπόλοιπες κατηγορίες χρησιμοποιούμε **diffuse prior**:

$$p_i \sim \text{Beta}(1, 1) \equiv \text{Uniform}(0, 1), \quad i = 2, 3, 4$$

Παρατήρηση 5. Η Beta κατανομή είναι η συζυγής prior (conjugate prior) για τη Binomial likelihood: αν $Y_i \sim \text{Bin}(n_i, p_i)$ και $p_i \sim \text{Beta}(\alpha, \beta)$, τότε η ύστερη κατανομή είναι $p_i \mid Y_i \sim \text{Beta}(\alpha + Y_i, \beta + n_i - Y_i)$.

Κώδικας WinBUGS

```
1 model {
2   # Likelihood
3   for (i in 1:N) {
4     y[i] ~ dbin(p[i], n[i])
5   }
6
7   # Informative prior για dose=0 κατηγορία( 1):
8   # Παλαιότερη μελέτη: 2 cases σε 40 trials
9   # Beta(2,38): E[p1] = 0.05, χαμηλή πιθανότητα
10  p[1] ~ dbeta(2, 38)
11
12  # Diffuse prior για τις υπόλοιπες κατηγορίες
13  p[2] ~ dbeta(1, 1)
14  p[3] ~ dbeta(1, 1)
15  p[4] ~ dbeta(1, 1)
16
17  # Odds Ratios σε σχέση με κατηγορία αναφοράς (dose=1)
18  OR2 <- (p[2]/(1-p[2])) / (p[1]/(1-p[1]))
19  OR3 <- (p[3]/(1-p[3])) / (p[1]/(1-p[1]))
20  OR4 <- (p[4]/(1-p[4])) / (p[1]/(1-p[1]))
21 }
```

Εκτέλεση WinBUGS

```
1 data_bugs_esoph <- list(y = y, n = n, N = N)
2 inits_esoph <- function() list(p = c(0.05, 0.25, 0.35, 0.85))
3
4 fit_esoph <- bugs(
5   data = data_bugs_esoph,
6   inits = inits_esoph,
7   parameters.to.save = c("p", "OR2", "OR3", "OR4"),
8   model.file = "C:/Users/Pavlina/Desktop/model_esoph.txt",
9   bugs.directory = "C:/WinBUGS14/winbugs14_full_patched/WinBUGS14/"
10 ,
11   n.chains = 1,
12   n.iter = 50000,
13   n.burnin = 5000
14 )
```

Αποτελέσματα


Πίνακας 4: Σύγκριση Bayesian και κλασικών εκτιμήσεων

Κατηγορία	MLE	95% CI (κλ.)	Bayes Mean	95% CrI
0--39g/day	0.0128	(0.0007, 0.0791)	0.0254	(0.0054, 0.0607)
40--79g/day	0.2469	(0.1608, 0.3575)	0.2529	(0.1660, 0.3522)
80--119g/day	0.3077	(0.1755, 0.4773)	0.3169	(0.1861, 0.4643)
120+g/day	0.8667	(0.5839, 0.9766)	0.8240	(0.6171, 0.9599)


Πίνακας 5: Bayesian Odds Ratios σε σχέση με κατηγορία 0--39g/day

Σύγκριση	OR (mean)	2.5%	97.5%
40--79 vs 0--39	19.88	4.56	68.19
80--119 vs 0--39	27.60	5.76	95.90
120+ vs 0--39	403.78	45.29	1799.02


Διαγνωστικά Γραφήματα



Σχήμα 12: Trace plots για p_1 , p_2 , p_3 , p_4 . Όλες οι αλυσίδες κινούνται τυχαία γύρω από σταθερή τιμή χωρίς drift, υποδηλώνοντας καλή σύγκλιση.




Σχήμα 13: Διαγράμματα αυτοσυσχέτισης. Μόνο το lag 0 είναι σημαντικό για όλες τις παραμέτρους — τα δείγματα είναι σχεδόν ανεξάρτητα, ένδειξη εξαιρετικής ανάμιξης.



Σχήμα 14: Running quantiles. Τα ποσοστημόρια σταθεροποιούνται μέσα στις πρώτες ~2000 επαναλήψεις, επιβεβαιώνοντας την επαρκή σύγκλιση.

Γράφημα Σύγκρισης



Σχήμα 15: Σύγκριση Bayesian (μπλε) και κλασικών MLE (κόκκινο) εκτιμήσεων με 95% διαστήματα. Οι σταυροί δείχνουν τις παρατηρηθείσες αναλογίες.

Σχολιασμός Αποτελεσμάτων

Επίδραση της Informative Prior. Για την κατηγορία dose=1 (0--39g/day), η Bayesian εκτίμηση (0.0254) είναι υψηλότερη από τον MLE (0.0128). Αυτό οφείλεται στην informative prior Beta(2, 38) με $E[p_1] = 0.05$ που "τραβάει" την εκτίμηση προς τα πάνω από τον MLE. Με μόλις 1 case σε 78 trials, η prior έχει σημαντική επίδραση στην κατηγορία αυτή.

Επίδραση της Κατανάλωσης Αλκοόλ. Τα Odds Ratios επιβεβαιώνουν ισχυρή και στατιστικά σημαντική σχέση μεταξύ κατανάλωσης αλκοόλ και καρκίνου οισοφάγου:

- Για 40--79g/day: τα odds καρκίνου είναι ~20 φορές υψηλότερα από ό,τι για 0--39g/day
- Για 80--119g/day: ~28 φορές υψηλότερα
- Για 120+g/day: ~404 φορές υψηλότερα — εξαιρετικά ισχυρή σχέση, αν και με μεγάλη αβεβαιότητα λόγω μικρού δείγματος ($n = 15$)

Σύγκριση Bayesian και Κλασικής Στατιστικής. Για τις κατηγορίες 2, 3, 4 οι Bayesian και κλασικές εκτιμήσεις είναι σχεδόν πανομοιότυπες, αφού χρησιμοποιήθηκαν diffuse priors. Η κύρια διαφορά εντοπίζεται στην κατηγορία 1 λόγω της informative prior. Η Bayesian προσέγγιση παρέχει:

- Πλήρη κατανομή αβεβαιότητας μέσω των posterior distributions
- Δυνατότητα ενσωμάτωσης προηγούμενης γνώσης
- Πιο σταθερές εκτιμήσεις για μικρά δείγματα (ιδιαίτερα για $n = 15$ στην κατηγορία 120+g/day)

Άσκηση 4

Jeffreys Prior για την Poisson κατανομή

Η Jeffreys prior είναι μια αντικειμενική πρότερη κατανομή που δεν εξαρτάται από τον τρόπο παραμετροποίησης του μοντέλου. Ορίζεται ως:

$$p(\lambda) \propto \sqrt{I(\lambda)}$$

όπου $I(\lambda)$ είναι η Fisher Information:

$$I(\lambda) = \mathbb{E} \left[-\frac{\partial^2}{\partial \lambda^2} \log f(x|\lambda) \right]$$

Για $X \sim \text{Poisson}(\lambda)$, η log-πυκνότητα είναι:

$$\log f(x|\lambda) = -\lambda + x \log \lambda - \log(x!)$$

Υπολογίζουμε:

$$\frac{\partial}{\partial \lambda} \log f(x|\lambda) = -1 + \frac{x}{\lambda}, \quad \frac{\partial^2}{\partial \lambda^2} \log f(x|\lambda) = -\frac{x}{\lambda^2}$$

Άρα:

$$I(\lambda) = \mathbb{E} \left[\frac{x}{\lambda^2} \right] = \frac{\mathbb{E}[x]}{\lambda^2} = \frac{\lambda}{\lambda^2} = \frac{1}{\lambda}$$

Επομένως η Jeffreys prior είναι:

$$p(\lambda) \propto \sqrt{\frac{1}{\lambda}} = \lambda^{-1/2}$$

Παρατήρηση 6. Πρόκειται για *ακατάλληλη κατανομή* (improper prior) αφού $\int_0^\infty \lambda^{-1/2} d\lambda = \infty$. Ωστόσο η ύστερη κατανομή είναι κατάλληλη, όπως θα δούμε παρακάτω.

Ύστερη Κατανομή κάτω από H_1

Από την Άσκηση 2, τα δεδομένα μας είναι $T = 35$ σφάλματα σε $n = 10$ ημέρες, με $T \sim \text{Poisson}(n\lambda)$. Η συνάρτηση πιθανοφάνειας είναι:

$$L(\lambda|T) \propto \lambda^T e^{-n\lambda} = \lambda^{35} e^{-10\lambda}$$

Εφαρμόζουμε το Θεώρημα Bayes:

$$p(\lambda|T) \propto L(\lambda|T) \cdot p(\lambda) \propto \lambda^{35} e^{-10\lambda} \cdot \lambda^{-1/2} = \lambda^{34.5} e^{-10\lambda}$$

Αναγνωρίζουμε πυρήνα Gamma με $\alpha^* = T + 1/2 = 35.5$ και $\beta^* = n = 10$:

$$\boxed{\lambda | T \sim \text{Gamma}(35.5, 10)}$$

με $\mathbb{E}[\lambda|T] = 35.5/10 = 3.55$ και $\text{Var}[\lambda|T] = 35.5/100 = 0.355$.

Αλγόριθμος Metropolis-Hastings

Ο αλγόριθμος Metropolis-Hastings μας επιτρέπει να δειγματολογούμε από την ύστερη κατανομή $p(\lambda|T)$ χωρίς να χρειάζεται η σταθερά κανονικοποίησης. Σε κάθε επανάληψη:

1. Προτείνουμε νέα τιμή: $\lambda^* \sim N(\lambda_{\text{current}}, \sigma^2)$
2. Υπολογίζουμε τον λόγο αποδοχής. Επειδή η Normal είναι συμμετρική ($q(\lambda^*|\lambda) = q(\lambda|\lambda^*)$), απλοποιείται σε:

$$\alpha = \min\left\{1, \frac{p(\lambda^*|T)}{p(\lambda_{\text{current}}|T)}\right\}$$

Σε log-κλίμακα:

$$\log \alpha = \log p(\lambda^*|T) - \log p(\lambda_{\text{current}}|T) = 34.5 \log \lambda^* - 10\lambda^* - 34.5 \log \lambda_{\text{current}} + 10\lambda_{\text{current}}$$

3. Αποδεχόμαστε λ^* με πιθανότητα α , αλλιώς κρατάμε το λ_{current}

Επιλογή σ^2 για Ποσοστό Αποδοχής 25%

```
1 # Log-posterior χωρίς σταθερά κανονικοποίησης
2 log_posterior <- function(lambda) {
3   if (lambda <= 0) return(-Inf)
4   (T_obs - 0.5) * log(lambda) - n_obs * lambda
5 }
6
7 # Αλγόριθμος Metropolis-Hastings
8 metropolis_hastings <- function(iter, sigma2, seed=123) {
9   set.seed(seed)
10  accept <- 0
11  samples <- numeric(iter)
12  current <- T_obs / n_obs # αρχική τιμή = MLE = 3.5
13
14  for (i in 1:iter) {
15    candidate <- rnorm(1, mean = current, sd = sqrt(sigma2))
16    log_alpha <- log_posterior(candidate) - log_posterior(current)
17    if (log(runif(1)) < log_alpha) {
18      current <- candidate
19      accept <- accept + 1
20    }
21    samples[i] <- current
22  }
23  list(samples = samples, accept_rate = accept/iter)
24 }
25
26 # Δοκιμή διαφορετικών τιμών sigma2
27 for (s2 in c(0.1, 0.5, 1, 2, 3, 5, 8, 10, 15)) {
28   test <- metropolis_hastings(20000, s2)
29   cat("sigma2 =", s2, "-> acceptance rate =",
30       round(test$accept_rate, 3), "\n")
31 }
```

Πίνακας 6: Ποσοστό αποδοχής για διαφορετικές τιμές σ^2

σ^2	Ποσοστό αποδοχής
0.1	0.829
0.5	0.653
1	0.544
2	0.440
3	0.374
5	0.306
8	0.250
10	0.227
15	0.187

Επιλέγουμε $\sigma^2 = 8$ που δίνει ποσοστό αποδοχής 25%, βέλτιστο για μονοδιάστατα προβλήματα.

Εκτέλεση Αλγορίθμου

```

1 sigma2_opt <- 8
2 total_iter <- 21000 # 20000 + 1000 burn-in
3 burnin <- 1000
4
5 result <- metropolis_hastings(total_iter, sigma2_opt)
6 lambda_samples <- result$samples[(burnin+1):total_iter]
```

Επιλογή Burn-in και Αριθμού Επαναλήψεων

Από τα διαγνωστικά γραφήματα:

- **Trace plot:** η αλυσίδα κινείται τυχαία γύρω από σταθερή τιμή ≈ 3.5 από τις πρώτες επαναλήψεις — υποδηλώνει γρήγορη σύγκλιση
- **Ergodic mean plot:** σταθεροποιείται μετά τις ~ 3000 επαναλήψεις — επιβεβαιώνει ότι burn-in = 1000 είναι συντηρητικά επαρκές
- **ACF plot:** σημαντική αυτοσυσχέτιση στα πρώτα ~ 10 lags — αναμενόμενο για MH με Normal proposal

Με συνολικά 21000 επαναλήψεις και burn-in = 1000, κρατάμε **20000 δείγματα**. Παρά την αυτοσυσχέτιση, ο αριθμός αυτός εξασφαλίζει ικανοποιητική ακρίβεια.


Αποτελέσματα

Πίνακας 7: Σύγκριση MH και αναλυτικής Gamma(35.5, 10)


	MH (Jeffreys)	Αναλυτική Gamma(35.5, 10)
Mean	3.5273	3.5500
SD	0.5830	0.5958
2.5%	2.5020	2.4796
97.5%	4.7293	4.8094

Η συμφωνία επιβεβαιώνει την ορθότητα του αλγορίθμου.


Διαγνωστικά Γραφήματα




Σχήμα 16: Trace plot της αλυσίδας MCMC. Η αλυσίδα κινείται τυχαία γύρω από σταθερή τιμή ≈ 3.5 από τις πρώτες επαναλήψεις. Η κόκκινη διακεκομμένη γραμμή δείχνει το burn-in = 1000.



Σχήμα 17: Εργοδική μέση τιμή της αλυσίδας. Συγκλίνει γρήγορα στο ≈ 3.55 και σταθεροποιείται μετά τις ~ 3000 επαναλήψεις, επιβεβαιώνοντας την επάρκεια του burn-in.



Σχήμα 18: Διάγραμμα αυτοσυσχέτισης. Παρατηρείται σημαντική αυτοσυσχέτιση στα πρώτα ~ 10 lags, αναμενόμενη για τον αλγόριθμο MH με Normal proposal. Σε αντίθεση με τον Gibbs sampler (Άσκηση 1Δ) που έδωσε σχεδόν μηδενική αυτοσυσχέτιση, εδώ τα διαδοχικά δείγματα δεν είναι ανεξάρτητα. Με 20000 δείγματα η ακρίβεια παραμένει ικανοποιητική.



Σχήμα 19: Ύστερη κατανομή του λ . Το ιστόγραμμα των δειγμάτων MH (μπλε) ταιριάζει εξαιρετικά με την αναλυτική $\text{Gamma}(35.5, 10)$ (κόκκινη γραμμή). Οι πράσινες διακεκομμένες γραμμές δείχνουν τα όρια του 95% διαστήματος αξιοπιστίας.

95% Συμμετρικό Διάστημα Αξιοπιστίας

Το 95% συμμετρικό διάστημα αξιοπιστίας υπολογίζεται ως τα 2.5% και 97.5% ποσοστημόρια των δειγμάτων MH:

$$\text{CI}_{95\%} = (2.502, 4.729)$$

Ερμηνεία: Με βάση τα παρατηρηθέντα 35 σφάλματα σε 10 ημέρες και τη Jeffreys prior, η πιθανότητα ο πραγματικός ρυθμός σφαλμάτων λ να βρίσκεται μεταξύ 2.502 και 4.729 είναι 95%. Για σύγκριση, η αναλυτική ύστερη $\text{Gamma}(35.5, 10)$ δίνει $\text{CI}_{95\%} = (2.480, 4.809)$ — σχεδόν πανομοιότυπο, επιβεβαιώνοντας την ακρίβεια του αλγορίθμου.

Συνολικό Συμπέρασμα

- Ο αλγόριθμος MH με Normal proposal $N(\lambda_{\text{current}}, \sigma^2 = 8)$ παράγει αξιόπιστα δείγματα από την ύστερη κατανομή $\lambda|T \sim \text{Gamma}(35.5, 10)$.
- Το ποσοστό αποδοχής 25% εξισορροπεί μεταξύ καλής εξερεύνησης του χώρου παραμέτρων και αποφυγής πολλών απορρίψεων.
- Η σημαντική αυτοσυσχέτιση (~ 10 lags) είναι χαρακτηριστική του MH — πλεονέκτημα του Gibbs sampler όταν είναι εφαρμόσιμος.
- Τα αποτελέσματα επιβεβαιώνουν το συμπέρασμα της Άσκησης 2: ο ρυθμός σφαλμάτων $\lambda \approx 3.5$, σημαντικά υψηλότερα από τη μηδενική υπόθεση $\lambda_0 = 2$.
- Η χρήση της Jeffreys prior $p(\lambda) \propto \lambda^{-1/2}$ αντί της $\text{Gamma}(2, 1)$ (Άσκηση 2) οδηγεί σε παρόμοια αποτελέσματα — με $T = 35$ παρατηρήσεις τα δεδομένα κυριαρχούν έναντι της prior.